

TRABAJO FIN DE GRADO

# PREDICCIÓN DE ENERGÍA SOLAR FOTOVOLTAICA A CORTO PLAZO MEDIANTE REDES NEURONALES A PARTIR DE DATOS POR SATÉLITE

TRABAJO FIN DE GRADO PARA  
LA OBTENCIÓN DEL TÍTULO DE  
GRADUADO EN INGENIERÍA EN  
TECNOLOGÍAS INDUSTRIALES

SEPTIEMBRE 2022

**Ricardo Modrego Eisman**

DIRECTOR DEL TRABAJO FIN DE GRADO:  
**Carlos Eduardo Guillén  
González**

*“La información es el aceite del Siglo XXI, y la analítica es el motor de combustión.”*

- Peter Sondergaard



## AGRADECIMIENTOS

Me resulta imprescindible dedicar unas palabras para agradecer a todas las personas que me han acompañado en este camino, que ha supuesto un reto apasionante.

A mi familia que ha tenido que aguantarme en los peores momentos, cuando estudiaba y no se veían los resultados o en las horas previas a las fechas de entrega.

A mis amigos, un apoyo muy importante en todo momento y sin los cuales no habría conseguido llegar hasta aquí, ya que es muy necesario un merecido descanso entre tanto trabajo para observar el presente y futuro con perspectiva. Gracias *Scan FC* y *Rials*.

Gracias a Ali por sacarme una sonrisa cuando la necesitaba y por el apoyo incondicional, una pieza fundamental en estos cuatro años.

Especial mención a mi tutor Carlos González Guillén por su guía e inestimable ayuda en los momentos complicados en la elaboración de este trabajo.



## RESUMEN EJECUTIVO

En la situación actual en la que se encuentra la sociedad a nivel mundial se hace imprescindible la investigación y perfeccionamiento de fuentes de energía para sustituir a las finitas y más contaminantes utilizadas actualmente. Las fuentes de energía no renovables disminuyen a medida que se consumen, por lo que su extracción resulta cada vez más complicada y su precio aumenta. Resulta llamativo el caso del petróleo. Desde la década de 1980, no solo se consume más petróleo del que se consigue, sino que esta relación es de 4 a 1 aproximadamente. Es decir, por cada 100 toneladas de petróleo que se consumen, solamente se descubren 25. Esto se relaciona con el hecho de que la demanda de todas las fuentes de energía continúa en aumento desde entonces, resultando en el inevitable agotamiento de las fuentes de energía no renovables. De hecho, de acuerdo con las predicciones actuales, las reservas de petróleo se agotarán en 40 o 50 años [21]. Como consecuencia, los países, como España, en los que las importaciones del petróleo tienen una elevada influencia en la economía se enfrentan a un difícil desafío como es modificar la estructura del sistema energético nacional.

Además, es sabido que las fuentes de energía no renovables más utilizadas actualmente como el petróleo, el carbón o el gas natural, generan residuos y emiten gases contaminantes a la atmósfera. Estos combustibles aúnan el 80 % de la demanda mundial de energía actual y, este sistema energético es el responsable de alrededor de dos tercios de las emisiones mundiales de CO<sub>2</sub>. Este gas, al ser de los conocidos como gases de efecto invernadero, acumula y emite calor. Como consecuencia, su presencia en la atmósfera es significado de aumento de la temperatura de la Tierra. [4]. No obstante, la emisión de gases contaminantes no es la única consecuencia ambiental del uso de energías no renovables. También son responsables de los vertidos de petróleo, la lluvia ácida, efectos perjudiciales sobre la salud humana, etc.

Por otro lado, la mayor parte de estos recursos está controlada por países concretos, lo que provoca que en épocas de tensión internacional como la actual se pueda producir escasez de energía en el resto de países, como España. Esto, a su vez, conlleva un aumento de precio de bienes necesarios para nuestra vida cotidiana tal como la conocemos como la electricidad o la gasolina.

En España, las energías renovables ya suponen una parte fundamental de la política energética nacional. Esto se debe a que nos permiten no solo minimizar la emisión de gases perjudiciales para la atmósfera y el medio ambiente, como el dióxido de carbono; sino también disminuir la dependencia de los combustibles fósiles, de manera que se reduce el uso de fuentes de energía no renovables y se utiliza energía local, por lo que se depende en menor medida de la energía importada. Además, las energías renovables se sitúan en precios competitivos debido al aumento del precio de los combustibles fósiles.

Sin embargo, las energías renovables también tienen desventajas y falta un gran camino por recorrer para poder eliminar la dependencia de las fuentes no renovables. Una de ellas, y de gran importancia en cuanto a la energía solar fotovoltaica, es su baja fiabilidad y dependencia climática. La dificultad para estimar la producción energética de una instalación fotovoltaica y, por tanto, la inversión necesaria para obtener la energía requerida supone un gran problema.

El objetivo de este trabajo es ayudar a mitigar esta incertidumbre y proponer alternativas para la predicción de la producción de energía solar fotovoltaica en campos solares. Se toman

datos de la planta solar de Ona Solar Mercat del Carmel (Carrer del Llobregós, 149, 08032 Barcelona), su producción de energía desde 2015 a 2018 compartidos en la página PVOutput, además del tamaño de la instalación y la marca y el modelo de los paneles fotovoltaicos. Por otro lado, se han obtenidos datos también públicos del satélite SARA2 sobre factores que influyen en la producción fotovoltaica, para el mismo intervalo temporal, como son la radiación solar: directa, difusa, reflejada y global; la altura del sol; la temperatura; y la velocidad del viento. A partir de estos datos se han empleado las técnicas más vanguardistas y que mejores resultados obtienen en este tipo de predicciones: *machine learning*. Se ha creado e implementado una red neuronal que aprende de los datos introducidos como entradas para predecir la producción. Esta previsión se ha centrado en el corto plazo: predecir la producción en los siguientes 15 minutos. Este reducido horizonte temporal se ha tomado debido a la creciente necesidad de conocer la producción de energía a corto plazo en empresas como Red Eléctrica Española, que participa en subastas de electricidad que se van a producir a 15 minutos vista.

El procedimiento del trabajo ha consistido en la reproducción y mejora de un artículo científico: “Solar Energy Prediction Model Based on Artificial Neural Networks and Open Data” [7], en la vanguardia de la predicción de energía solar fotovoltaica. Los autores de este artículo han tomado datos de distintos parques solares situados en distintos países europeos, mientras que en este trabajo se ha tomado un parque solar situado en España, por lo que las condiciones de predicción cambian. Un ejemplo es el tiempo atmosférico que puede ser más o menos estable, lo que facilitaría o dificultaría las predicciones. Además, no se detalla el algoritmo utilizado, simplemente se dan unas pinceladas sobre la red neuronal, al igual que con los datos utilizados. Como consecuencia, una gran parte del trabajo ha consistido en la obtención y posterior depurado de datos adecuados para poder llevar a cabo la predicción. Otra parte notable ha consistido en la reproducción del algoritmo empleado en el artículo, teniendo como objetivo llegar a resultados similares a los suyos -no pueden ser idénticos ya que no se han utilizado los mismos datos ni el mismo algoritmo- a partir de los cuales poder introducir mejoras que ayuden a disminuir el error de predicción y, por tanto, arrojar luz sobre la incertidumbre que produce la producción de energía solar fotovoltaica.

Para llevar a cabo esta mejora se han utilizado modelos de redes neuronales convolucionales. Estas redes neuronales se utilizan principalmente para el tratamiento y reconocimiento de imágenes, y de esta manera han sido utilizadas en este trabajo. Para entrenar esta red neuronal se han tomado datos atmosféricos y de radiación solar, en vez de en la localización concreta de la instalación solar fotovoltaica, en puntos distribuidos a lo largo de un cuadrado de 81 kilómetros cuadrados en cuyo centro se encuentra la planta solar. De esta manera, obtenemos tres matrices (una para cada componente de la radiación: directa, difusa y reflejada), semejantes a las matrices de las imágenes a color en el sistema *RGB* (rojo, verde y azul), con las que se puede representar cualquier imagen. Cada una de las matrices de 9x9 elementos recoge los datos de radiación en todas las ubicaciones del mapa cuadrado alrededor de la planta. Esto ha dado lugar a unos resultados positivos, ya que se ha conseguido disminuir el error del modelo desarrollado en el artículo mediante la aplicación de esta nueva técnica.

El hecho de conseguir mejorar el modelo de predicción de energía solar fotovoltaica mediante el empleo de redes neuronales convolucionales supone un paso adelante en el desarrollo de esta energía. Se ayuda a predecir su producción, con lo que disminuye la incertidumbre sobre su rendimiento, un factor que limita en gran medida su implantación como fuente de energía. Por tanto, significa un avance en la sustitución de las fuentes de energía contaminantes y no renovables, por fuentes limpias y renovables.

**Palabras clave:** energía renovable, fotovoltaica, machine learning, predicción, corto plazo, red neuronal convolucional.



# Índice

<b>1. INTRODUCCIÓN</b>	<b>12</b>
1.1. Antecedentes . . . . .	12
1.2. Justificación . . . . .	13
1.3. Estado del arte . . . . .	14
<b>2. OBJETIVOS</b>	<b>17</b>
<b>3. METODOLOGÍA</b>	<b>18</b>
3.1. Fundamento Teórico . . . . .	18
3.1.1. Energía Solar Fotovoltaica . . . . .	18
3.1.1.1. Funcionamiento de las instalaciones fotovoltaicas . . . . .	18
3.1.1.2. Factores influyentes en la producción . . . . .	19
3.1.2. Inteligencia Artificial . . . . .	23
3.1.2.1. Agentes impulsores de la inteligencia artificial . . . . .	24
3.1.2.2. Redes Neuronales . . . . .	25
3.2. Datos Utilizados . . . . .	36
3.2.1. Datos Descargados . . . . .	36
3.2.2. Procesamiento de datos . . . . .	39
3.2.2.1. PVOutput . . . . .	39
3.2.2.2. PVGIS . . . . .	40
3.3. Criterios de evaluación de los resultados . . . . .	42
<b>4. RESULTADOS Y DISCUSIÓN</b>	<b>44</b>
4.1. Modelos de Redes Neuronales . . . . .	44
4.1.1. Réplica del artículo . . . . .	44
4.1.1.1. Datos de entrada de radiación y atmosféricos . . . . .	44
4.1.1.2. Datos de entrada de la producción . . . . .	44

4.1.1.3.	Frecuencia de los datos de entrada . . . . .	44
4.1.1.4.	Estructura de la red neuronal . . . . .	45
4.1.1.5.	Cantidad de datos de entrenamiento y validación . . . . .	46
4.1.1.6.	Parámetros de la ejecución . . . . .	46
4.1.1.7.	Modelos . . . . .	46
4.1.2.	Mejora del modelo . . . . .	50
4.1.2.1.	Introducción de la producción . . . . .	50
4.1.2.2.	Red Neuronal Convolucional . . . . .	51
<b>5.</b>	<b>CONCLUSIONES</b>	<b>58</b>
<b>6.</b>	<b>LÍNEAS FUTURAS</b>	<b>60</b>
<b>7.</b>	<b>RESPONSABILIDAD SOCIAL, AMBIENTAL Y PROFESIONAL</b>	<b>61</b>
<b>8.</b>	<b>PLANIFICACIÓN TEMPORAL Y PRESUPUESTO</b>	<b>62</b>
8.1.	Planificación temporal . . . . .	62
8.2.	Presupuesto . . . . .	64
<b>9.</b>	<b>BIBLIOGRAFÍA</b>	<b>67</b>



# 1. INTRODUCCIÓN

## 1.1. Antecedentes

Se prevé que la demanda de energía a nivel mundial se duplique o incluso triplique para 2050 [9], y es sabido que la mayor parte de la energía utilizada hoy en día es no renovable. Más allá de los perjuicios al planeta -emisión de gases que acrecientan el efecto invernadero, emisión de gases que destruyen la capa de ozono, etc.-, y a la propia salud -emisión de gases y partículas que afectan al sistema respiratorio, contaminación de aguas, etc.- estas fuentes de energía, como su propio nombre indica, son finitas y se van terminar consumiendo por completo. Esto ha conllevado un aumento de la conciencia social sobre el cambio climático y las energías renovables están ganando tracción en todo el mundo. Además, en la Agenda 2030 se tiene como objetivo aumentar considerablemente la proporción del uso de energías renovables con respecto a otras fuentes de energía. De esta manera, poder utilizar fuentes de energía limpias y renovables que cubran la creciente demanda energética es uno de los mayores desafíos a los que se enfrenta la sociedad actual. Las energías renovables más utilizadas actualmente, como la solar fotovoltaica o la hidráulica, serían idóneas de no ser por su poca fiabilidad. Son fuentes limpias y que no dependen de recursos que se agoten -como la luz solar-, así que de ser capaces de dominar la cantidad de energía que va a producir anualmente un parque solar en un lugar determinado o una presa hidráulica, se podrían implantar las instalaciones suficientes para cubrir la demanda esperada y cumplir el desafío actual.

Sin embargo, la producción energética de las instalaciones de energías renovables varía en gran medida dependiendo de las características de la localización en la que se sitúan y sus condiciones atmosféricas, geológicas, topográficas, etc. El suministro intermitente de electricidad procedente de estas fuentes (sobregeneración o infrageneración) puede provocar inseguridad energética para los consumidores, lo que afecta negativamente al mercado. Este es un gran obstáculo al que se enfrentan las energías renovables, ya que utilizando otras fuentes de energía como centrales térmicas o nucleares se sabe a ciencia cierta la cantidad de energía que va a ser generada, lo que supone una gran ventaja competitiva frente a la energía solar fotovoltaica. Por tanto, es crucial para su desarrollo diseñar modelos de predicción de confianza y precisos para la producción de energía fotovoltaica. Los errores de previsión, que pueden producirse a través de los operadores del sistema, la tecnología aplicada, y debido a condiciones atmosféricas concretas, se encuentran entre los principales desafíos. Según numerosos estudios, estos errores afectan a la economía de la operación y a la productividad.

En España, la energía solar fotovoltaica es la fuente de energía renovable que más crece actualmente, con un crecimiento del 28,8 % en 2021 [5] y se prevé que esta cifra continúe aumentando debido a las características climáticas del país, que lo convierte en un lugar idóneo para la instalación de paneles fotovoltaicos, ya sea para uso personal o industrial. Además, la radiación solar en la superficie de la Tierra alcanza entorno a 6800 veces el consumo total anual [17]. Estos hechos muestran el gran potencial que tiene la energía solar fotovoltaica en España y la gran oportunidad energética ante la que nos encontramos.




Figura 1.1: Evolución energía solar fotovoltaica en España [15].

## 1.2. Justificación

Durante los dos últimos años se ha producido una vertiginosa subida del precio de la electricidad: el precio del MWh se ha incrementado un 494 % desde 2020 hasta 2022, pasando de un precio total de 40,4 €/MWh en 2020 a 118,7 €/MWh en 2021 y finalmente a 199,5 €/MWh en lo que llevamos de 2022 [12]. Esto supone un problema económico, no solamente para industrias, sino también para domicilios particulares a la hora de hacer frente a la factura de la luz.

Se ha demostrado la importancia del sector solar fotovoltaico en España como fuente de energía, que supone una parte importante de la aportación al mercado eléctrico español. Mejorando las predicciones de producción de electricidad de los agentes vendedores en el mercado eléctrico se puede contribuir a un descenso del precio final del megavatio hora (MWh). El motivo principal es que los agentes del mercado eléctrico compran y venden energía dependiendo del precio, que se rige en gran medida por la oferta y la demanda. Por lo tanto, haciendo uso de predicciones acertadas podrán elegir el momento óptimo de compra y venta, reduciendo costes.

Por otro lado, unas previsiones acertadas también ayudarían económicamente a los gestores de los parques solares, ya que serían capaces de ajustar el tamaño de la instalación para obtener la cantidad de energía que desean. De esta manera, encontrarían el tamaño óptimo para su instalación, lo que también les permitiría reducir costes y maximizar beneficios, que a su vez también se podría ver reflejado en las subastas del mercado eléctrico ya que permitiría a las empresas generadoras de energía vender el MWh a un precio más reducido obteniendo el mismo beneficio.




Figura 1.2: Precio total del MWh en España por meses [13].

### 1.3. Estado del arte

Una parte crucial del trabajo consiste en la documentación, adquisición de conocimiento y familiarización con las técnicas más utilizadas en la actualidad a la hora de predecir la producción de energía solar fotovoltaica en parques solares. La mayor parte de la literatura existente sobre predicciones de este estilo se centra en la predicción de la radiación solar, pero este trabajo se centra en un paso más allá, la predicción de la energía fotovoltaica. A continuación se exponen las principales ideas extraídas de la literatura revisada que han sido de utilidad para realizar el trabajo.

Para abarcar estos problemas, se han utilizado distintas técnicas: físicas, estadísticas e inteligencia artificial. Las técnicas físicas comprenden un grupo de expresiones algebraicas que explican el estado físico y la variabilidad dinámica de la atmósfera. Estos modelos se desarrollan principalmente a partir de las características del sistema fotovoltaico. Estas características incluyen la información meteorológica y de orientación histórica de la estación en estudio. En función de los conjuntos de datos utilizados de los parámetros de entrada los modelos físicos pueden ser simples o complejos. En las técnicas estadísticas, las previsiones a corto y muy corto plazo se utilizan a menudo. En general, sólo utilizan conjuntos de datos generados por la planta fotovoltaica como parámetros de entrada para la previsión. Al igual que las técnicas físicas, las estadísticas se ven afectadas en los días nublados y de lluvia, en los que tienden a perder precisión. Los modelos estadísticos comúnmente desarrollados para previsión de la generación de energía incluyen modelos de regresión lineal, modelos de regresión lineal multivariante, modelos de regresión no lineales, modelos de media móvil autorregresiva (ARMA) y modelos autorregresivos (AR), además de modelos de series temporales no estacionarias como el modelo de media móvil integrada autorregresiva (ARIMA) y el modelo de media móvil integrada autorregresiva con entrada exógena (ARIMAX). Los modelos de Redes Neuronales son las técnicas de inteligencia artificial más adoptadas y se han aplicado desde la última década para predecir la energía

fotovoltaica producida. Las ANN han demostrado desde sus primeros usos para predecir esta energía un nivel de precisión más alto que los enfoques estadísticos tradicionales, especialmente para los casos que incluyen bases de datos no lineales. [17]

En primer lugar, del artículo “Solar Energy Prediction Model Based on Artificial Neural Networks and Open Data” (Modelo de Predicción de Energía Solar Basado en Redes Neuronales y Datos Públicos) [7] se ha obtenido una información importante sobre los factores que afectan a la predicción de energía fotovoltaica, y por tanto, los datos de entrada relevantes para la red neuronal. Estos son: la radiación solar, descompuesta en sus tres componentes (directa, difusa y reflejada), el ángulo de acimut solar (ángulo formado entre el Norte y el Sol, medido en el sentido de las agujas de un reloj alrededor del horizonte del observador), la temperatura del aire, la velocidad del viento y valores propios de la instalación fotovoltaica como su tamaño y rendimiento. Más adelante se estudiará qué datos ayudan realmente a la producción de energía solar. Por otro lado, dado que este artículo ha sido replicado, también se han obtenido de él las fuentes de datos: PVOutput -para la producción de los paneles solares utilizados- y PVGIS -para la obtención de datos relativos a los factores atmosféricos previamente mencionados-. Además, se han reproducido las estructuras de los modelos de redes neuronales utilizadas en el artículo para poder optimizarlas. Su mejor modelo de redes neuronales consiste en una capa estratificada de neuronas, dos capas ocultas, datos de la radiación descompuestos en sus componentes -directa, difusa y reflejada- y un número de neuronas en cada capa definido por la siguiente fórmula:  $\text{Neuronas} = 1/2 * (\text{Entrada} + \text{Salida}) + \text{SQRT}(\text{Entrenamiento})$ , siendo Entrada = Número de elementos o dimensiones de la capa de entrada, Salida = Número de elementos o dimensiones de la capa de salida, Entrenamiento = Número de muestras. En este modelo han obtenido un error cuadrático medio (MSE) de 0.040 y un error absoluto medio (MAE) de 0.161.

Cabe mencionar el artículo “Solar power forecasting using artificial neural networks” (Predicción de energía solar utilizando redes neuronales) [3]. En este artículo también se predice la energía solar fotovoltaica mediante un algoritmo de redes neuronales creado en MATLAB, se calcula a lo largo de un mes y se compara el modelo mediante el cálculo de la raíz cuadrada del error cuadrático medio (RMSE), cuyo resultado varía entre 0.069–0.055 en el peor y mejor mes predichos, respectivamente. Además, se realiza una distinción entre el día y la noche, ya que por la noche la energía producida es cero y se llega a la conclusión de que para predecir la energía producida durante el día, es mejor no utilizar las horas de la noche para entrenar el modelo. Por otra parte, en el artículo “24-Hour-ahead forecasting of energy production in solar PV systems” (Predicción de producción de energía solar en sistemas fotovoltaicos a 24 horas vista) [10], resulta interesante que para la discusión y comparación de los resultados se calcula el error estacional, es decir, la media de los errores cometidos diariamente durante los días de esa estación, y se alcanza un error cuadrático medio (MSE) de: 0.122 en primavera, 0.211 en verano y 0.266 entre abril y septiembre. Merece la pena mencionar el artículo “Contribution to the quantification of solar radiation in Algeria” (Contribución a la cuantificación de la radiación solar en Argelia [23]) , en el que se mide la radiación solar en vez de la energía fotovoltaica producida. En este artículo, se obtiene un error absoluto medio (MAE) entre 0.0157–0.0418 en el mejor y peor modelo, respectivamente, aunque es importante notar que las predicciones las realizan en localizaciones diferentes. Es normal que esto de lugar a una diferencia de errores entre modelos, ya que las condiciones pueden variar entre una zona y otra (como mayor estabilidad, y, por tanto, mayor facilidad en la predicción).

Por otro lado, del artículo “Ultra-short-term exogenous forecasting of photovoltaic power production using genetically optimized non-linear auto-regressive recurrent neural networks”

(Predicción exógena a muy corto plazo de producción de energía fotovoltaica utilizando redes neuronales recurrentes optimizadas genéticamente, no lineales autorregresivas) [17] se ha obtenido información sobre los métodos utilizados para la predicción. Inicialmente se utilizaban métodos físicos, más adelante estadísticos y, actualmente, predominan las técnicas de inteligencia artificial. Además, ha permitido aprender sobre las estructuras más exitosas de redes neuronales. Los distintos tipos de funciones de activación más utilizados en este tipo de predicciones: sigmoide, ReLU y tangente hiperbólica.



## 2. OBJETIVOS

El objetivo de este trabajo es desarrollar un modelo de redes neuronales que prediga la producción de energía solar fotovoltaica a corto plazo mejorando modelos existentes, realizando de esta manera una aportación a mejorar la fiabilidad de las energías renovables y reducir su incertidumbre. Partiendo del artículo escrito por tres investigadores de la Universidad de Alicante [7], se han reproducido sus resultados con los datos disponibles para posteriormente mejorar el algoritmo mediante dos enfoques diferentes y llegar a predicciones más precisas.

Para lograr este objetivo se ha partido de dos fuentes de datos distintas: la primera proporciona la energía solar fotovoltaica producida por un parque solar español y la segunda datos atmosféricos mediante satélite, incluyendo la radiación solar de esta zona para poder predecir su producción. El estudio se ha centrado en la predicción utilizando datos meteorológicos, de manera que se pueda predecir con mayor facilidad la producción ante cambios atmosféricos repentinos. El primer enfoque de mejora está basado en el uso de la primera fuente, concretamente, en introducir datos de la producción anteriores para mejorar el modelo. Mientras que el segundo enfoque está relacionado con la obtención de datos de radiación en un área que rodea a la instalación solar y tratarlos como una imagen mediante la creación de redes neuronales convolucionales.

### 3. METODOLOGÍA

#### 3.1. Fundamento Teórico

##### 3.1.1. Energía Solar Fotovoltaica

##### 3.1.1.1 Funcionamiento de las instalaciones fotovoltaicas

Para poder desarrollar un algoritmo de predicción de la producción de energía solar fotovoltaica es necesario conocer el proceso de producción de esta energía, desde el funcionamiento de los paneles fotovoltaicos hasta los factores que afectan a la producción.

En primer lugar, la energía solar fotovoltaica es una fuente de energía renovable y limpia que aprovecha la radiación solar para generar electricidad. Se basa en el llamado efecto fotoeléctrico, en el que determinados materiales son capaces de absorber fotones (partículas de luz) y liberar electrones, generando así una corriente eléctrica. Para ello se utilizan dispositivos semiconductores denominados celdas o células fotovoltaicas, que pueden estar hechos de silicio monocristalino, policristalino o amorfo, u otros materiales semiconductores de película delgada. El silicio monocristalino se obtiene de monocristales de silicio puro y tiene la eficiencia más alta, con un promedio de entre un 18 % y un 20 %. Los de silicio policristalino están formados por varios cristales, por lo que son más económicos y proporcionan una eficiencia media del 16 % al 17,5 %.

Finalmente, el desorden de red del silicio amorfo da como resultado un desempeño más pobre (8 % a 9 % de eficiencia promedio) pero un coste también más reducido [19].




Figura 3.1: Esquema simplificado del efecto fotoeléctrico en un panel fotovoltaico [6].

Existen dos tipos diferentes de plantas fotovoltaicas: las conectadas a la red y las no conec-

tadas. En primer lugar, las conectadas a la red se pueden dividir en:

- Central fotovoltaica: la totalidad de la energía producida por los paneles fotovoltaicos alimenta a la red eléctrica.
- Generador con autoconsumo: un porcentaje de la electricidad producida es consumida por el productor (como los paneles instalados en los tejados de las viviendas, por ejemplo) y la electricidad que no se consume es vertida a la red. A su vez, el productor utiliza la energía necesaria de la red para cubrir su demanda cuando los paneles fotovoltaicos no le proporcionan la energía suficiente (por la noche, por ejemplo).

Estas instalaciones conectadas a la red están formadas por tres elementos:

- Paneles fotovoltaicos: son grupos de celdas fotovoltaicas montadas entre capas de silicio que reciben la radiación solar y transforman la luz (fotones) en energía eléctrica (electrones).
- Inversores: convierten la corriente eléctrica continua producida por los paneles en corriente alterna, de manera que esté disponible para consumirse.
- Transformadores: la corriente alterna producida por los inversores es de baja tensión (entre 380 y 800 V), así que se utiliza un transformador para convertirla a media tensión (hasta 36 kV).

Por otro lado, las instalaciones sin conectar a la red trabajan de forma autónoma y es frecuente encontrarlas en lugares remotos y explotaciones agrícolas para satisfacer demandas de iluminación, servir de apoyo a las telecomunicaciones o bombear los sistemas de riego. Estas plantas requieren, además de los elementos básicos descritos, dos adicionales para su funcionamiento:

- Baterías: su función consiste en almacenar la energía fotovoltaica producida y no consumida en ese instante para cuando sea demandada.
- Reguladores: actúan como protección de la batería ante sobrecargas y evitan un uso ineficiente. [19]

### **3.1.1.2 Factores influyentes en la producción**

Los factores que afectan a la producción de energía solar fotovoltaica se pueden dividir en tres tipos: factores ambientales, factores del sistema fotovoltaico y factores de la instalación del sistema fotovoltaico.

#### **Factores ambientales**

En primer lugar, se encuentra la radiación solar, definida como la cantidad de energía procedente del Sol por unidad de superficie. La energía producida por un módulo fotovoltaico está directamente relacionada con la disponibilidad de energía solar y, por lo tanto, depende del lugar en el que esté instalado, ya que la radiación suele fluctuar en función del clima y de la ubicación del Sol en el cielo. La ubicación del Sol cambia a lo largo del día debido a sus cambios en la

altitud, que es el ángulo entre los rayos solares y el plano horizontal, y el ángulo acimutal, que es el ángulo entre el norte y la proyección de los rayos solares sobre la horizontal en el cielo. Es importante resaltar que la radiación solar que incide sobre una superficie está compuesta por tres componentes: radiación directa, difusa y reflejada.

- Radiación directa: es la componente de la radiación que alcanza directamente la superficie del panel.
- Radiación difusa: es la componente de la radiación que alcanza la superficie del panel tras ser desviada por algún elemento atmosférico, como pueden ser las nubes.
- Radiación reflejada: es la componente de la radiación que alcanza la superficie del panel después de ser reflejada en otro objeto.




Figura 3.2: Esquema de los componentes de la radiación. [11]

La mayor parte de la radiación solar es la componente directa; sin embargo, tanto la radiación difusa como la reflejada deben tenerse en cuenta durante el análisis del funcionamiento del sistema. Además, la radiación solar sobre los paneles fotovoltaicos varía con la posición de los propios módulos; la máxima radiación solar tiene lugar cuando los paneles están perpendiculares a la componente directa. Algunos estudios mostraron que se produce una pérdida del 0,08 % por cada grado de desviación respecto al sur [29]. Como es de esperar, a medida que aumenta la radiación solar, también aumenta la potencia eléctrica del panel fotovoltaico, de hecho, la relación entre la corriente del módulo y la radiación solar es aproximadamente lineal.

En segundo lugar, se encuentra la temperatura del módulo, que está estrechamente relacionada con la radiación, la temperatura del aire y la velocidad del viento. Una célula fotovoltaica convierte una pequeña parte, aproximadamente menos del 20 % (como se ha descrito anteriormente), de la radiación en energía eléctrica, mientras que el resto se convierte en calor. El sobrecalentamiento del módulo se produce principalmente debido a la excesiva radiación solar y a las altas temperaturas. La temperatura del módulo es un parámetro que tiene gran influencia en el comportamiento de un sistema fotovoltaico, ya que afecta en gran medida a la eficiencia del sistema y a la producción de energía. El principal efecto del aumento de la temperatura de la célula es sobre la tensión en circuito abierto, que disminuye linealmente con el aumento de

la temperatura de la célula [25]. Existen algunas correlaciones propuestas en la literatura que expresan la temperatura del módulo en función de variables como las meteorológicas (depende de la ubicación) especialmente la temperatura ambiente, la velocidad del viento local, así como la incidencia solar o de la radiación en el plano del conjunto. Además, la temperatura depende del material y de las propiedades del sistema, como la absorción de la placa. De esto se puede concluir que no hay un rango exacto de pérdidas porcentuales de potencia debido al aumento de la temperatura de los módulos fotovoltaicos. En la figura 2 se muestra el descenso de la eficiencia conforme aumenta la temperatura de los paneles.




Figura 3.3: Descenso de la eficiencia con la temperatura [14].

En tercer lugar, se encuentra la presencia de partículas de polvo en el aire. Una parte de la luz solar puede quedar bloqueada en el módulo fotovoltaico debido a la presencia de suciedad o polvo, lo que provoca una cantidad considerable de pérdidas en la energía generada, ya que la radiación solar se dispersa en la superficie del panel solar. Un factor de reducción de polvo anual típico es del 93 % , por lo que si tomamos un módulo de 100 vatios como ejemplo, normalmente funcionará a unos 93 W debido a la acumulación de suciedad [14]. Sin embargo, la deposición de polvo es específica del clima del lugar y, por lo tanto, su cantidad depende del lugar, del tipo de polvo y de numerosos factores, por lo que este porcentaje puede variar.

Además, también relacionado con la radiación solar, encontramos el efecto de la sombra. La potencia de salida de los paneles fotovoltaicos se reduce drásticamente debido al efecto de sombra. Las sombras no sólo afectan al flujo de corriente en las celdas que reciben sombra sino que afectan a todo el panel ya que normalmente las células están conectadas y cableadas en serie. Las sombras pueden ser causadas por postes, árboles, edificios, las estructuras de montaje de los módulos en otras estructuras, hojas, pájaros y diversos objetos que pueden caer directamente sobre los módulos también pueden causar sombra. La cuantificación de las pérdidas debidas a la sombra depende del porcentaje de células sombreadas, así como del material de la célula y de la conexión entre los paneles, pero, tras revisar numerosos estudios, se obtiene que si un 5 % de las células se encuentran bajo la sombra, se puede reducir la producción total del panel hasta un 70 %. [14]

#### **Factores del sistema fotovoltaico**

El ratio de conversión de los paneles solares tienen una gran influencia sobre la cantidad de energía generada, dependiendo de la radiación recibida. Actualmente, hay una gran variedad de paneles fotovoltaicos, con diversas características que ofrecen numerosos rendimientos. Dentro de los factores que afectan a este rendimiento, encontramos: el material del panel fotovoltaico, puede ser de silicio, arseniuro de galio (GaAs), diseleniuro de cobre e indio (CuInSe<sub>2</sub>), telururo de cadmio (CdTe), fosfuro de indio y muchos otros; la estructura atómica del panel fotovoltaico: monocristalina, policristalina, amorfa, etc.

#### **Factores de la instalación del sistema fotovoltaico**

En la instalación también intervendrán factores que determinarán el rendimiento de la instalación fotovoltaica. Estos son:

- I Características del cableado: los cables utilizados en el sistema fotovoltaico conectado a la red deben seleccionarse cuidadosamente para garantizar que puedan soportar las posibles condiciones extremas del entorno, la tensión y la corriente en las que se espera que funcionen.
- II El ángulo de inclinación u orientación de los paneles: como se ha descrito anteriormente, el mayor rendimiento se alcanza cuando los paneles son perpendiculares a la radiación directa, por tanto si se utilizan paneles fijos se deben instalar tras estudiar el ángulo de inclinación óptimo para maximizar el rendimiento. También se pueden instalar paneles fotovoltaicos con mecanismos de seguimiento del Sol de uno o dos ejes.
- III Efectos de desajuste: las pérdidas por desajuste se deben a la conexión en serie y en paralelo de módulos, especialmente los que no tienen propiedades comunes. Uno de los problemas más graves asociados a el desajuste es que la potencia de todo el conjunto fotovoltaico está determinada por el módulo solar con la menor potencia, por lo que el rendimiento del conjunto depende en gran medida del grado de variación de los módulos que componen el conjunto, de las células solares que forman los módulos fotovoltaicos y también del tipo de conexiones en serie y en paralelo de los módulos fotovoltaicos en la red. El desajuste de los módulos supone una pérdida de al menos el 2 % de la potencia del sistema potencia del sistema y a veces puede llegar al 10 %, siendo las pérdidas medias del 6 %. [14]

### 3.1.2. Inteligencia Artificial

En 1956, en una conferencia en la Universidad de Dartmouth, los académicos propusieron formalmente el término “inteligencia artificial”. Ese momento fue el primer paso en un nuevo tema de estudio de cómo las máquinas simulan las actividades inteligentes humanas. A principios de 2016, AlphaGo - un programa informático de inteligencia artificial desarrollado por Google DeepMind- derrotó al campeón mundial de Go. Este acontecimiento despertó inmediatamente el interés mundial por la inteligencia artificial (IA).

Muchos estudiosos iniciaron investigaciones relacionadas con la IA desde finales del siglo XX. Esta utiliza ordenadores para simular comportamientos inteligentes humanos y entrena a los ordenadores para que aprendan comportamientos humanos como el aprendizaje, el juicio y la toma de decisiones. La IA es una recopilación de las ciencias de la computación, la lógica, la biología, la psicología, la filosofía y muchas otras disciplinas, y ha logrado resultados notables en aplicaciones como el reconocimiento del habla, el procesamiento de imágenes, el procesamiento del lenguaje natural, la demostración de teoremas automáticos y los robots inteligentes. Actualmente, la IA desempeña un papel indispensable en el desarrollo social, y ha aportado resultados revolucionarios en la mejora de la eficiencia laboral, la reducción de los costes laborales, la optimización de la estructura de los recursos humanos y la creación de nuevas demandas de empleo.

La inteligencia artificial es el estudio de cómo hacer que los ordenadores realicen tareas inteligentes que, en el pasado, sólo podían realizar los humanos [18]. En los últimos años, la IA se ha desarrollado rápidamente y ha cambiado el estilo de vida de las personas, convirtiéndose este desarrollo en una importante estrategia de desarrollo para los países de todo el mundo, para mejorar la competitividad nacional y mantener la seguridad. Muchos países han introducido políticas preferenciales y han reforzado el despliegue de tecnologías y talentos clave para tomar la delantera en una nueva ronda de competencia internacional [26]. La IA se ha convertido en un punto álgido de investigación en ciencia y tecnología; grandes empresas como Google, Microsoft e IBM están comprometidas con la IA y la están aplicando a cada vez más campos.

La inteligencia artificial ha experimentado un largo proceso de desarrollo, con una historia de más de 70 años. Su proceso de desarrollo puede dividirse en varias etapas: en 1943 se propuso el modelo de la neurona artificial, lo que abrió la era de la investigación de las redes neuronales artificiales. En 1956, se celebró la Conferencia de Dartmouth y se propuso el concepto de inteligencia artificial; esto marcó su nacimiento. Durante este periodo, la tendencia de la investigación en inteligencia artificial por parte de la comunidad académica internacional estaba en alza, y los intercambios académicos eran frecuentes. En la década de 1960, la tecnología inteligente experimentó un retroceso en su desarrollo. La investigación sobre el algoritmo de propagación hacia atrás (*backpropagation*) comenzó en los años 70, y el coste y la potencia de cálculo computacional aumentaron gradualmente, lo que dificultó su investigación y aplicación. Avanzar se hizo difícil, pero la inteligencia artificial fue logrando poco a poco avances. En los años 80, las redes neuronales de propagación hacia atrás fueron ampliamente reconocidas, la investigación de algoritmos basados en redes neuronales artificiales se desarrolló rápidamente, las funciones del hardware de los ordenadores mejoraron rápidamente y el desarrollo de Internet redujo el desarrollo de la inteligencia artificial. En la primera década del siglo XXI, el desarrollo de Internet móvil trajo más escenarios de aplicación de la inteligencia artificial. En 2012, se propuso el aprendizaje profundo, y la inteligencia artificial logró un gran desarrollo.

#### 3.1.2.1 Agentes impulsores de la inteligencia artificial

##### Big data

El *big data* es un requisito necesario para la inteligencia artificial, y es un factor central que promueve la IA para mejorar la tasa de reconocimiento y la precisión. Con el desarrollo y la amplia aplicación del Internet de las cosas (*IoT*), la cantidad de datos generados ha aumentado exponencialmente, con una gran tasa de crecimiento anual. Además de aumentar el número, la dimensión de los datos también se ha ampliado. Estas grandes cantidades de datos de alta dimensión hacen que los datos sean más completos y suficientes para apoyar el desarrollo de la IA.

##### Algoritmos

En el reconocimiento tradicional de patrones, los investigadores resumían las leyes y los métodos. Sin embargo, este método de abstracción tiene grandes limitaciones y una baja precisión. Posteriormente, los investigadores se inspiraron en el ser humano, en concreto a los bebés nadie les enseña a reconocer objetos, pero ellos aprenden. Basándose en esto, se ha propuesto un método de aprendizaje automático que resume las leyes y los métodos de identificación de objetos. Por ejemplo, si se introducen muchas fotos de perros en un ordenador, éste puede aprender las características de los perros mediante modelos de entrenamiento (como las redes neuronales) y puede reconocer con precisión a los perros en otras fotos basándose en estas características [27]. El aprendizaje automático permite que los ordenadores aprendan y analicen automáticamente grandes cantidades de datos, para luego tomar decisiones y hacer predicciones sobre los acontecimientos del mundo real. Los algoritmos hacen posible la IA. Y más allá de la aplicación de algoritmos relevantes para la IA en el campo del reconocimiento de patrones, también se han logrado resultados satisfactorios en otros campos, entre ellos el reconocimiento del habla, los motores de búsqueda, el análisis semántico y los sistemas de recomendación (como en las plataformas para ver vídeos, series o películas). Cada uno de ellos ha progresado considerablemente bajo el impulso de los algoritmos de IA.

##### Machine Learning

La idea básica del aprendizaje automático es el uso de un algoritmo que mejora su rendimiento aprendiendo de los datos. Los cuatro tipos de problemas más importantes que deben resolverse mediante el aprendizaje automático son la predicción, la agrupación, la clasificación y la reducción de la dimensión. Teniendo en cuenta la clasificación de los métodos de aprendizaje, el aprendizaje automático puede dividirse en cuatro categorías: aprendizaje supervisado, aprendizaje no supervisado, aprendizaje semi-supervisado y aprendizaje por refuerzo [8]. El aprendizaje supervisado se refiere al uso de datos etiquetados para entrenar, con el fin de predecir el tipo o el valor de los nuevos datos. Según los diferentes resultados de predicción, se puede dividir en dos categorías: clasificación y regresión. Los métodos típicos de aprendizaje supervisado son Máquinas de Vectores de Soporte (SVM) y la discriminación lineal. El problema de regresión se refiere a la predicción de la salida de valores continuos, por ejemplo, se podrían analizar los datos del precio de la vivienda, ajustarlos según la entrada de datos de la muestra, y luego obtener una curva continua para predecir los precios de la vivienda. El problema de clasificación se refiere a la predicción de la salida de valores discretos, como juzgar si la foto actual es un perro o un gato basándose en una serie de características propias de cada uno de ellos. El valor de salida es 1 o 0.

Cuando los datos no tienen etiquetas, el aprendizaje no supervisado es la minería de datos



y se refleja principalmente en la agrupación. En resumen, los datos pueden clasificarse según diferentes características sin etiquetas. Los métodos típicos de aprendizaje no supervisado son el K-Medias (*K-Means*) y el análisis de componentes principales. La premisa importante del K-Means es que la diferencia entre los datos puede medirse mediante la distancia euclídea. Si no se puede medir, hay que convertirla en una distancia euclídea utilizable. El análisis de componentes principales es un método estadístico. Mediante una transformación ortogonal, las variables relevantes se transforman en variables no correlacionadas; las variables transformadas se denominan componentes principales. La idea básica es sustituir los indicadores originales relacionados por un conjunto de indicadores independientes y completos.

En su significado más literal, el aprendizaje semi-supervisado puede entenderse como una mezcla de aprendizaje supervisado y aprendizaje no supervisado. De hecho, los datos etiquetados y los no etiquetados se mezclan en el proceso de aprendizaje. En circunstancias normales, la cantidad de datos sin etiquetar es mucho mayor que la cantidad de datos etiquetados. La idea del aprendizaje semi-supervisado es ideal, pero no se utiliza mucho en las aplicaciones prácticas.

El aprendizaje por refuerzo es un método para obtener recompensas interactuando con el entorno, juzgando la calidad de las acciones por los niveles de recompensa, y luego entrenando el modelo. La importancia de la exploración y el desarrollo en el aprendizaje por refuerzo es un tema espinoso: para obtener mejores recompensas, las personas deben elegir la acción que puede obtener la mayor recompensa, pero también deben encontrar acciones desconocidas. El fundamento del aprendizaje por refuerzo procede de la psicología del comportamiento. En 1911, Thorndike propuso una regla eficaz: en un entorno que hace que las personas o los animales se sientan cómodos, las personas o los animales seguirán reforzando esta acción. A la inversa, si una persona o un animal se siente incómodo, la persona o el animal reducirá su movimiento. En otras palabras, el aprendizaje por refuerzo puede potenciar la conducta de recompensa y debilitar la de castigo. Se puede entrenar el modelo mediante el mecanismo de ensayo y error para encontrar el mejor funcionamiento y comportamiento para obtener el mayor rendimiento. Esto imita el modelo de aprendizaje de los humanos o de los animales y no necesita guiar a los agentes para que aprendan en una determinada dirección [28].

## Hardware

En el aprendizaje automático, se utilizan algunos modelos de redes neuronales profundas para resolver problemas complejos. La plataforma de hardware que ejecuta el aprendizaje profundo es principalmente una unidad de procesamiento gráfico (GPU) producida por NVIDIA. La GPU es un nuevo modelo de computación que utiliza procesadores paralelos masivos para acelerar aplicaciones con funciones paralelas. En el pasado, la CPU (en castellano, Unidad Central de Procesamiento) tardaba un mes en obtener los resultados de un entrenamiento, que ahora la GPU puede obtener en un día [28]. Las potentes funciones de cálculo paralelo de la GPU alivian los cuellos de botella en el entrenamiento de los algoritmos de aprendizaje profundo, liberando así el potencial de la inteligencia artificial.

### 3.1.2.2 Redes Neuronales

Los pájaros inspiraron al ser humano a volar, las plantas de bardana inspiraron el velcro, y un sinnúmero de inventos más se inspiraron en la naturaleza. Parece lógico, pues, fijarse en la arquitectura del cerebro para inspirarse en cómo construir una máquina inteligente. Esta es la idea clave que dio origen a las redes neuronales. Sin embargo, aunque los aviones se inspiraron

en los pájaros, no tienen que batir las alas. Del mismo modo, las redes neuronales se han ido diferenciando de sus primos biológicos.

Las redes neuronales son el núcleo del aprendizaje profundo. Son versátiles, potentes y escalables, por lo que son ideales para abordar tareas de aprendizaje automático grandes y muy complejas como la clasificación de miles de millones de imágenes -por ejemplo *Google Images*-, el reconocimiento del habla de voz -*Siri* de Apple-, recomendar los mejores vídeos a cientos de millones de usuarios cada día -YouTube-, o aprender a vencer al campeón del mundo de *Go* jugando millones de partidas contra sí mismo -*Alpha-Zero* de *DeepMind*-.

Pese a que hasta hace pocos años las redes neuronales no gozasen de una gran popularidad, existen desde hace prácticamente 80 años: fueron introducidas por primera vez en 1943 por el neurofisiólogo Warren McCulloch y el matemático Walter Pitts. En su histórico artículo “*A Logical Calculus of Ideas Immanent in Nervous Activity*” [22] McCulloch y Pitts presentaron un modelo computacional simplificado de cómo las neuronas biológicas podrían trabajar juntas en los cerebros de los animales para realizar computaciones complejas utilizando la lógica proposicional. Esta fue la primera arquitectura de red neuronal artificial. Sus primeros éxitos hasta la década de 1960 llevaron a la creencia generalizada de que pronto estaríamos conversando con máquinas verdaderamente inteligentes. Cuando quedó claro que esta creencia no se cumpliría -al menos durante un tiempo-, perdieron financiación y las redes neuronales pasaron a un segundo plano.

A principios de la década de 1980 resurgió el interés por el estudio de las redes neuronales, ya que se inventaron nuevas arquitecturas y se desarrollaron mejores técnicas de entrenamiento. Pero los avances fueron lentos, y en la década de 1990 se inventaron otras técnicas potentes de aprendizaje automático, como las máquinas de vectores de soporte (*Support Vector Machines*). Estas técnicas parecían ofrecer mejores resultados y fundamentos teóricos más sólidos que las redes neuronales, por lo que, de nuevo, pasaron a un segundo plano. Actualmente se ha reactivado el interés y el uso de las redes neuronales, pero en esta ocasión hay razones para pensar que tendrán un mayor impacto, como las siguientes.

- Actualmente se dispone de una enorme cantidad de datos para entrenar redes neuronales, y las redes neuronales suelen superar a otras técnicas de aprendizaje automático en problemas muy grandes y complejos.
- El enorme aumento de la potencia de cálculo desde la década de 1990 permite ahora entrenar grandes redes neuronales en un tiempo razonable. Esto se debe en parte a la Ley de Moore, formulada por el ingeniero Gordon Moore en 1965 que afirmó que el número de transistores por unidad de superficie en circuitos integrados se duplicará cada año. Aunque en 1975 modificó su ley para incrementar el intervalo temporal dos años. Además, también en gran medida a la industria del juego, que ha producido millones de potentes tarjetas GPU.
- Los algoritmos de entrenamiento se han mejorado, se han realizado pequeños ajustes que tienen un gran impacto positivo.
- Algunas limitaciones teóricas de las redes neuronales han resultado inofensivas en la práctica. Por ejemplo, se pensaba que los algoritmos de entrenamiento de las redes neuronales estaban condenados a quedarse atascados en los óptimos locales, pero resulta que no es nada frecuente en la práctica y si ocurre, suelen estar bastante cerca del óptimo global.

- Las redes neuronales han entrado en una dinámica positiva en términos de financiación y progreso. Productos revolucionarios basados en las redes neuronales aparecen con cierta frecuencia en los medios de comunicación, lo que aumenta su popularidad y financiación, resultando en un progreso cada vez mayor.

Warren McCulloch y Walter Pitts propusieron un modelo muy simple de la neurona biológica, que más tarde se conoció como neurona artificial: tiene una o más entradas binarias (activa/inactiva) y una salida binaria. La neurona artificial simplemente activa su salida cuando más de un determinado número de sus entradas están activas. Demostraron que incluso con un modelo tan simplificado es posible construir una red de neuronas artificiales que calcule cualquier proposición lógica que se desee. Desde este modelo las redes neuronales han sufrido un gran desarrollo, a continuación se exponen definiciones de elementos que se utilizarán para construir la red neuronal.

### Perceptrón

Un perceptrón o neurona artificial recoge varias entradas y lleva a cabo una suma ponderada para producir una salida. El peso del perceptrón se determina durante el proceso de entrenamiento y se basa en los datos de entrada. Este es un diagrama de un perceptrón:

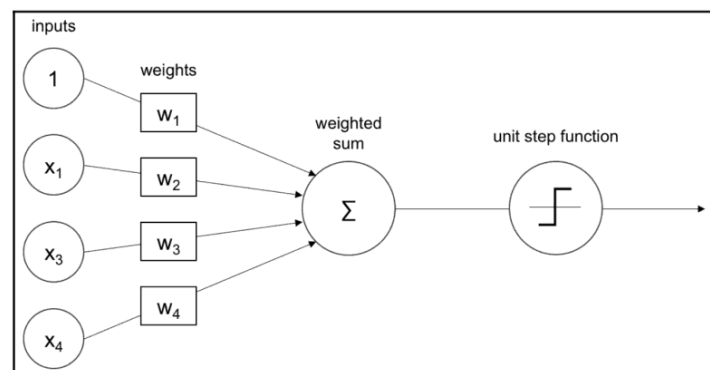


Figura 3.4: Diagrama de un perceptrón [24].

Las entradas son ponderadas y sumadas como se muestra en la figura. Posteriormente se aplica la función escalón unitario a la suma, en este caso. Un perceptrón sólo puede aprender funciones simples aprendiendo los pesos de los ejemplos, este proceso se llama entrenamiento. El entrenamiento de un perceptrón se suele realizar mediante métodos de descenso del gradiente. A la salida del perceptrón se le puede aplicar una función de activación o de transferencia.

### Funciones de activación

Las funciones de activación hacen que las salidas de las neuronas sean no-lineales. Una función de activación decide si el perceptrón será ejecutado o no. Durante el entrenamiento las funciones de activación cumplen un papel importante ajustando los gradientes. Una función de activación como la sigmoide atenúa los valores con mayores magnitudes. Este comportamiento no-lineal de las funciones de activación permite el aprendizaje de funciones complejas. La mayoría de las funciones de activación son continuas y diferenciables. En una función continua pequeños cambios en la entrada producen pequeños cambios en la salida y una función derivable admite derivada en cualquier punto del dominio, condición necesaria para entrenar una red neuronal para la posterior optimización de la función de pérdidas.

- I La Sigmoide se puede considerar como una función escalón suavizada y, por tanto, diferenciable. Asocia a cada valor de entrada un valor entre 0 y 1, como se muestra en la siguiente figura:




Figura 3.5: Gráfica de la sigmoide [24].

Sin embargo, tiene un problema asociado al método del descenso del gradiente utilizado para minimizar la función de pérdidas (función objetivo a minimizar, en nuestro caso es el error cuadrático medio en la predicción). El descenso del gradiente realiza iteraciones sobre los parámetros proporcionales al valor negativo del gradiente en el punto actual. El algoritmo usa la propagación hacia atrás para poder calcular el valor del gradiente y corregir adecuadamente los parámetros del modelo. Para que así el error de predicción sea cada vez menor. Para calcular la influencia del peso de la salida de una neurona al error global, hay que calcular la derivada de la función de coste con respecto al parámetro de la primera capa. Utilizando la regla de la cadena, cuanto más grande sea la red neuronal se va a producir un mayor número de multiplicaciones, aquí surge el problema, ya que la derivada de la función sigmoide se encuentra siempre acotada entre 0 y 0.25. Por tanto, estamos multiplicando numerosas veces -dependiendo del tamaño de la red- números entre 0 y 0.25, por lo que el valor del gradiente es muy próximo a 0, siendo las neuronas más lentas de entrenar. Este problema se conoce como desvanecimiento del gradiente.

- II La función tangente hiperbólica, o  $\tanh$ , es la versión escalada de la sigmoide. También es suave y diferenciable. La  $\tanh$  devuelve un valor entre -1 y 1, como se muestra en la siguiente figura:




Figura 3.6: Gráfica de la función tangente hiperbólica [24].

Los gradientes son más estables que con la sigmoide, ya que su derivada alcanza valores mayores que 0,25 y, por tanto, tienen menos problemas de desvanecimiento del gradiente. Ambas funciones, sigmoide y tanh se ejecutan siempre, lo que hace que la red neuronal sea realmente pesada.

- III La función ReLU (*Rectified Linear Unit*) permite dejar pasar grandes números, esto hace que alguna neurona no se ejecute, lo que es positivo ya que disminuye el tamaño de la red neuronal. La función ReLU devuelve para un valor  $x$  el máximo entre 0 y  $x$ . Esto es, para los valores negativos devuelve 0 y los positivos no sufren ningún cambio, como se muestra en la figura:




Figura 3.7: Gráfica de la función ReLU [24].

Como la función ReLU no se activa continuamente, puede ser entrenada más rápidamente, al ser una función simple, requiere menor carga computacional. La elección de la función de activación es muy dependiente de la aplicación. Sin embargo, la función ReLU funciona satisfactoriamente para una gran variedad de problemas y es la que se utilizará en este trabajo.

### Red Neuronal

Una red neuronal es una combinación de perceptrones y funciones de activación. Los perceptrones se conectan formando capas o unidades ocultas. Estas capas ocultas forman la base no-lineal que transforma las capas de entrada en capas de salida con una menor dimensión. Por tanto, la red neuronal no es más que una función entre la entrada y la salida. Esta función se computa mediante la suma ponderada de las entradas con sesgos. Los valores de los pesos y sesgos más la arquitectura se llaman modelo.

El proceso de entrenamiento determina los valores de los pesos y sesgos. Los valores del modelo se inicializan con datos aleatorios al principio del entrenamiento y el error se calcula utilizando una función de pérdidas contrastándolo con datos conocidos. Basado en los errores computados, los pesos varían en cada paso hasta que las pérdidas no se pueden reducir más y finaliza el proceso de entrenamiento. La figura muestra un diagrama de una red neuronal o perceptrón multicapa:




Figura 3.8: Diagrama Red Neuronal [24].

Las distintas entradas de  $X$  se ven sometidas a capas ocultas de perceptrones y sumadas en la salida. Cada capa puede tener una de las funciones de activación descritas anteriormente. El número de capas ocultas y perceptrones se puede elegir dependiendo del problema.

### Dropout

Dropout es una manera efectiva de regularizar redes neuronales para evitar el sobre ajuste de la red. Durante el entrenamiento, la capa de Dropout criba la red neuronal eliminando capas ocultas estocásticamente como se muestra en la siguiente figura:




Figura 3.9: Descripción gráfica del Dropout [24].

Cabe destacar que las neuronas son entrenadas aleatoriamente. La función Dropout también es una manera efectiva de combinar distintas redes neuronales. Para cada caso de entrenamiento, seleccionamos aleatoriamente distintas capas ocultas de manera que se obtengan diferentes arquitecturas de la red neuronal para cada caso.

### Entrenamiento de redes neuronales

El entrenamiento de redes neuronales no es trivial ya que contiene diversos parámetros a optimizar. El procedimiento para actualizar los pesos se llama propagación hacia atrás (*backpropagation*). El procedimiento para minimizar la función de pérdidas -el error- se conoce como optimización.

### Propagación hacia atrás

Este algoritmo se utiliza frecuentemente para entrenar redes neuronales. Actualizándose los pesos hacia atrás basados en los errores calculados. Después de calcular el error, se puede usar el descenso del gradiente para calcular la actualización de los pesos.

### Descenso del gradiente

El algoritmo de descenso del gradiente lleva a cabo una optimización multidimensional, cuyo objetivo es minimizar la función de pérdidas. Esta es una técnica de optimización popular utilizada en numerosos modelos de *machine learning*. Se utiliza para mejorar u optimizar las predicciones de los modelos. Una implementación del descenso del gradiente es el descenso estocástico del gradiente y es popular en las redes neuronales. La optimización incluye calcular el valor del error y cambiar el valor de los pesos para minimizarlo. La dirección para encontrar el mínimo es el gradiente negativo de la función de pérdidas. Este procedimiento se puede observar cualitativamente en la figura:




Figura 3.10: Descripción gráfica del descenso del gradiente [24].

La tasa de aprendizaje determina cómo de grande debe ser cada paso. Nótese que una red neuronal con funciones de activación no lineales tiene un mínimo local.

### Librería TensorFlow

TensorFlow es una librería de fuente abierta para el desarrollo e implementación de modelos de aprendizaje profundo (*deep learning*). Utiliza gráficos computacionales para el flujo de datos y los cálculos numéricos. En otras palabras, es el flujo de datos o tensores como indica su nombre. El gráfico tiene nodos que permiten cualquier computación numérica y, por tanto, son adecuados para las operaciones de aprendizaje profundo. Proporciona una única API para todos los tipos de plataformas. TensorFlow se encarga de la complejidad de escalar y optimizar. Fue desarrollado para investigación en Google y es la librería más utilizada para aprendizaje profundo, con una gran comunidad y herramientas para la visualización e implementación.

### Librería Keras

Keras es otra librería de fuente abierta para aprendizaje profundo escrita en Python. Proporciona una interfaz de fácil acceso a TensorFlow, aunque también se puede utilizar con otras librerías como Theano o Microsoft Cognitive Toolkit (CNTK). Está diseñada para experimentación fácil y rápida. Es un marco autónomo y funciona sin problemas entre CPU y GPU. Puede ser instalada por separado o usada conjuntamente con TensorFlow utilizando la API `tf.keras`, esto tiene ventajas ya que ofrece características extra muy útiles, como que permite utilizar la API de datos de TensorFlow, lo cual hace más fácil cargar y preprocesar datos eficientemente [24].

**Redes Neuronales Convolucionales** Las redes neuronales convolucionales (CNN) surgieron del estudio de la corteza visual del cerebro y se han utilizado en el reconocimiento de imágenes desde la década de 1980. En los últimos años, gracias al aumento de la potencia de cálculo, a la cantidad de datos de entrenamiento disponibles y al desarrollo de nuevas técnicas para el entrenamiento de redes profundas, las redes neuronales convolucionales han alcanzado un rendimiento sorprendente en algunas tareas visuales complejas. Son la base de los servicios de búsqueda de imágenes, de los coches que se conducen solos, de los sistemas de clasificación automática de vídeos y de muchos otros. Además, estas redes neuronales no se limitan a la percepción visual: también tienen éxito en muchas otras tareas, como el reconocimiento de voz o el procesamiento del lenguaje natural (NLP).

El bloque de construcción más importante de una red neuronal convolucional es la capa convolucional: las neuronas de la primera capa convolucional no están conectadas a cada uno de los píxeles de la imagen de entrada, sino sólo a los píxeles de sus campos receptivos, una determinada parte de la imagen. A su vez, cada neurona de la segunda capa convolucional está conectada sólo a las neuronas situadas dentro de un pequeño rectángulo de la primera capa. Esta arquitectura permite que la red se concentre en pequeñas características de bajo nivel en la primera capa oculta, para luego ensamblarlas en características de mayor nivel en la siguiente capa oculta, y así sucesivamente. Esta estructura jerárquica es común en las imágenes del mundo real, y es una de las razones por las que las CNN funcionan tan bien para el reconocimiento de imágenes. En la siguiente figura se muestra de forma gráfica:




Figura 3.11: Entrada a una red neuronal convolucional [16].

Los pesos de una neurona pueden representarse como una pequeña imagen del tamaño del campo receptivo. Por ejemplo, la figura 3.12 muestra dos posibles conjuntos de pesos, llamados filtros. El primero se representa como un cuadrado negro con una línea blanca vertical en el centro (es una matriz de  $7 \times 7$  llena de ceros excepto la columna central, que está llena de unos); las neuronas que utilicen estos pesos ignorarán todo en su campo receptivo excepto la línea vertical central (ya que todas las entradas se multiplicarán por 0, excepto las situadas en la línea vertical central). El segundo filtro es un cuadrado negro con una línea blanca horizontal en el centro. Una vez más, las neuronas que utilicen estos pesos ignorarán todo lo que haya en su campo receptivo excepto la línea horizontal central. Ahora bien, si todas las neuronas de una capa utilizan el mismo filtro de línea vertical (y el mismo término de sesgo), y se alimenta a la red con la imagen de entrada inferior mostrada en la figura, la capa emitirá la imagen



superior izquierda. Cabe resaltar que las líneas blancas verticales se resaltan mientras que el resto se difumina. Del mismo modo, la imagen superior derecha es la que se obtiene si todas las neuronas utilizan el mismo filtro de líneas horizontales; obsérvese que las líneas blancas horizontales se resaltan mientras que el resto se difumina. Así, una capa llena de neuronas que utilizan el mismo filtro produce un mapa de características que resalta las áreas de una imagen que activan más el filtro. Por supuesto, no es necesario definir los filtros manualmente: durante el entrenamiento, la capa convolucional aprenderá automáticamente los filtros más útiles para su tarea, y las capas superiores aprenderán a combinarlos en patrones más complejos.

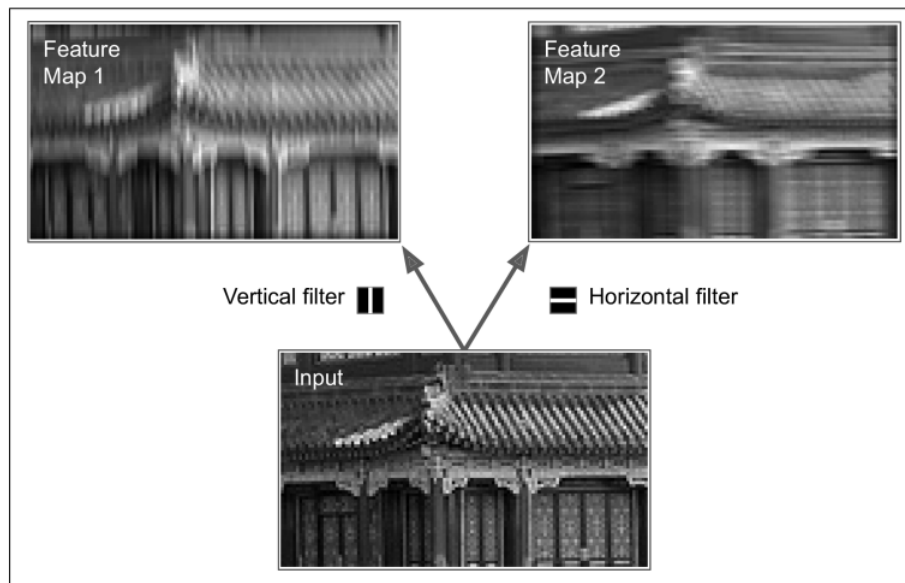


Figura 3.12: Aplicación de dos filtros distintos para obtener dos características [16].

Hasta ahora, para simplificar, se ha representado la salida de cada capa convolucional como una fina capa 2D, pero en realidad una capa convolucional tiene múltiples filtros (el número deseado por el creador del modelo), y da salida a un mapa de características por filtro, por lo que se representa con más precisión en 3D, como se puede observar en la figura 3.13. Para ello, tiene una neurona por píxel en cada mapa de características, y todas las neuronas dentro de un mapa de características determinado comparten los mismos parámetros (es decir, los mismos pesos y término de sesgo). Sin embargo, las neuronas de diferentes mapas de características utilizan parámetros diferentes. El campo receptivo de una neurona es el mismo que el descrito anteriormente, pero se extiende por todos los mapas de características de las capas anteriores. En resumen, una capa convolucional aplica simultáneamente múltiples filtros que se entrenan a sus entradas, lo que la hace capaz de detectar múltiples características en cualquier lugar de sus entradas. Además, las imágenes de entrada también se componen de múltiples subcapas: una por canal de color. Normalmente hay tres: rojo, verde y azul (RGB). Las imágenes en escala de grises tienen un solo canal, pero algunas imágenes pueden tener muchos más; por ejemplo, las imágenes de satélite que captan frecuencias de luz adicionales (como los infrarrojos). [16]

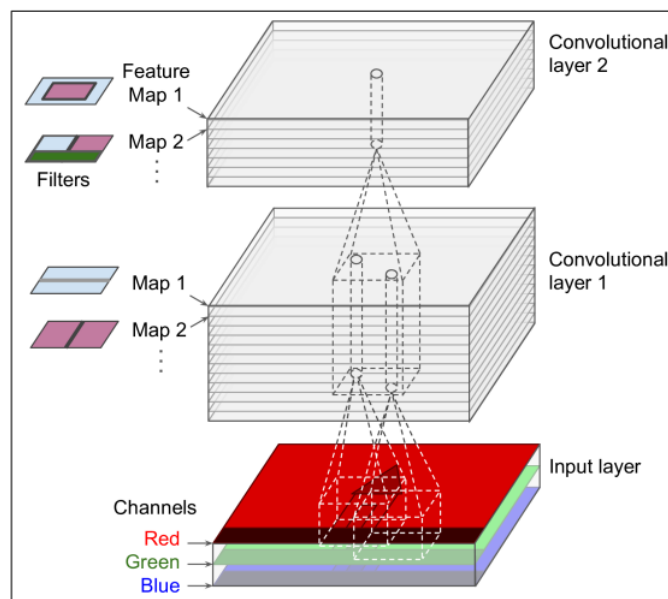


Figura 3.13: Aplicación de dos filtros distintos para obtener dos características [16].

Un problema de las CNN es que las capas convolucionales requieren una gran cantidad de memoria RAM. Esto es especialmente cierto durante el entrenamiento, ya que la propagación hacia atrás requiere todos los valores intermedios calculados durante el paso anterior. Por ejemplo, consideremos una capa convolucional con  $5 \times 5$  filtros, que produce 200 mapas de características de tamaño  $150 \times 100$ . Si la entrada es una imagen RGB de capa convolucional de  $150 \times 100$  (tres canales), el número de parámetros es  $(5 \times 5 \times 3 + 1) \times 200 = 15.200$  (el +1 corresponde a los términos de sesgo), lo que aún es pequeño en comparación con una capa totalmente conectada. Sin embargo, cada uno de los 200 mapas de características contiene  $150 \times 100$  neuronas, y cada una de estas neuronas tiene que calcular una suma ponderada de sus  $5 \times 5 \times 3 = 75$  entradas: eso es un total de 225 millones de multiplicaciones. No es tanto cálculo como una capa totalmente conectada, pero sigue siendo bastante intensivo desde el punto de vista computacional. Además, si los mapas de características se representan con números tipo *float* de 32 bits, la salida de la capa convolucional ocupará  $200 \times 150 \times 100 \times 32 = 96$  millones de bits (12 MB) de RAM. Y eso es sólo para un ejemplo, si un lote de entrenamiento contiene 100 ejemplos, esta capa utilizará 1,2 GB de RAM.

Una vez que se entiende cómo funcionan las capas convolucionales, las capas de agrupación son bastante fáciles de entender. Su objetivo es reducir la imagen de entrada para disminuir así la carga computacional, el uso de memoria y el número de parámetros (limitando también el riesgo de sobreajuste). Al igual que en las capas convolucionales, cada neurona de una capa de agrupación está conectada a las salidas de un número limitado de neuronas de la capa anterior, situadas dentro de un pequeño campo receptivo rectangular. Hay que definir su tamaño, la zancada y el tipo de relleno. Sin embargo, una neurona de agrupación no tiene pesos; todo lo que hace es agregar las entradas utilizando una función de agrupación como el máximo o la media. La Figura 3.14 muestra una capa de agrupación máxima (se queda con el valor máximo del campo receptivo que abarca), que es el tipo más común de capa de agrupación.




Figura 3.14: Ejemplo de una capa de agrupación máxima [16].

En este ejemplo, se utiliza una capa de agrupación de  $2 \times 2$  con una zancada de valor 2 y sin relleno. Sólo el valor máximo de entrada en cada campo receptivo pasa a la siguiente capa, mientras que las demás entradas se descartan.

Las arquitecturas típicas de las redes neuronales convolucionales consisten en varias capas convolucionales (cada una de ellas generalmente con la función de activación ReLU), después una capa de agrupación, de nuevo varias capas convolucionales, luego otra capa de agrupación, y así sucesivamente. La imagen es cada vez más pequeña a medida que avanza por la red, pero también suele ser cada vez más profunda (es decir, con más mapas de características) gracias a las capas convolucionales (véase la figura 3.15). En la parte final de la arquitectura, se añade una red neuronal regular de avance, compuesta por varias capas totalmente conectadas (con funciones de activación ReLU), y la capa final emite la predicción. [16]




Figura 3.15: Arquitectura característica de una red neuronal convolucional [16].

### 3.2. Datos Utilizados

#### 3.2.1. Datos Descargados

Una vez analizados los factores que intervienen en la producción de la energía solar fotovoltaica, se sabe qué datos, a priori, deben ser introducidos en el modelo para que aprenda y prediga la producción. Es sabido la gran cantidad de datos disponibles en la actualidad referentes a prácticamente cualquier tema, sin embargo, para entrenar la red neuronal no es válido cualquier conjunto de datos, sino que ha de cumplir determinados requisitos para obtener el resultado buscado.

En primer lugar, se han buscado datos de la producción de un parque solar instalado en España y además, de cuya localización se puedan obtener los datos atmosféricos requeridos, en el intervalo temporal del que seleccionamos la producción. Además, el conjunto de datos seleccionado debe contener la siguiente información:

- I Información sobre la cantidad de energía generada por esa instalación.
- II Información sobre los factores solares.
- III Información sobre los factores geológicos y atmosféricos.
- IV Información sobre los factores eléctricos que conforman esa instalación.

Tras analizar numerosas páginas web y métodos de obtención de datos, se han utilizado estas dos páginas para obtenerlos:

- PVOutput [2]: Un servicio gratuito para compartir y comparar datos de producción fotovoltaica. Aunque para obtener datos de instalaciones fotovoltaicas requieren una donación. Proporciona grandes volúmenes de datos en bruto relacionados con la producción solar fotovoltaica. A partir de esta fuente de datos, se puede obtener información sobre la cantidad de energía generada por una instalación en un rango de tiempo, información sobre el ángulo azimutal solar, e información sobre los factores eléctricos que conforman esa instalación.
- Sistema de Información Geográfica Fotovoltaica (PVGIS) [1]: PVGIS es un sistema desarrollado por el Centro Común de Investigación de la Comisión Europea, en la sede del CCI en Ispra, Italia, desde 2001. El objetivo de PVGIS es el estudio y difusión de conocimientos y datos sobre la radiación solar y el rendimiento fotovoltaico. La información disponible en la plataforma es la radiación solar mensual, diaria e incluso horaria. Utiliza datos de alta calidad y alta resolución espacial y temporal de la radiación solar obtenidos a partir de imágenes de satélite, así como la temperatura ambiente y la velocidad del viento de los modelos de análisis climático. Por lo tanto, cumple con el requisito de los factores solares en un rango de tiempo específico y la información sobre la temperatura del aire y la velocidad del viento para ese rango de tiempo.

Para el entrenamiento y validación del modelo, se ha seleccionado una instalación fotovoltaica en Barcelona. Para seleccionar la instalación se ha tenido en cuenta, además de que estuviesen disponibles los datos requeridos para los conjuntos de datos anteriormente descritos, que debe proporcionarse la siguiente información:

- I Ubicación, en el sistema de coordenadas universal transversal de Mercator (UTM).

- II Marca y modelo de los paneles solares instalados.
- III Datos completos (o casi completos) durante el periodo seleccionado (entre 2015 y 2018, incluyendo datos de la energía generada cada día).
- IV Orientación e inclinación de los paneles solares instalados.

Tras filtrar las instalaciones que cumplieran todas estas condiciones, se tomó la instalación de Ona Solar Mercat del Carmel, cuyas características son:

- Dirección: Carrer del Llobregós, 149, 08032 Barcelona.
- Tamaño: 43740 W.
- Máxima potencia de los paneles: 180W.
- Número de paneles: 243.
- Marca y modelo de los paneles: STM 180F.
- Orientación e inclinación: Sur 0.0, inclinación de 35 grados.
- Fecha de instalación: 1 de enero de 2015.
- Inversores: 10 inversores, cuya marca y modelo es FRONIUS IG 60 ADV y tienen un tamaño de 4860 W
- Eficiencia de los módulos: 14.439 %
- Rango de datos disponibles: desde el 9 de marzo de 2015 a las 14:15, hasta el 16 de diciembre de 2018.
- Código de identificación de la planta en PVOutput: 34434



Figura 3.16: Ubicación de la instalación solar fotovoltaica a estudio.

De esta instalación fotovoltaica, obtuvimos los siguientes parámetros de PVOutput:

- I Tamaño de la instalación (kW)
- II Energía generada (kWh/día)
- III Ratio de conversión de la energía solar (%). Este valor puede obtenerse del fabricante del panel solar teniendo en cuenta el modelo y la marca.

Esta información se complementa obteniendo los datos de la radiación solar de PVGIS. Estos datos provienen de satélites que forman parte de METEOSAT: PVGIS -SARAH, PVGIS-CMSAF, PVGIS-ERA5. La API del servicio web también proporciona datos como el ángulo de inclinación del panel y el acimut, devolviendo la cantidad de radiación solar recibida directamente por los paneles solares en el punto deseado. Los datos proporcionados por PVGIS tienen la siguiente estructura:

- Fecha de los datos con formato: YYYY/DD/MM:HH:mm (24h).
- Radiación directa en el panel fotovoltaico (W/m<sup>2</sup>).
- Radiación difusa en el panel fotovoltaico (W/m<sup>2</sup>).
- Radiación reflejada en el panel fotovoltaico (W/m<sup>2</sup>) .
- Altura del sol (grados).
- Temperatura del aire (grados Celsius).
- Velocidad del viento (m/s).

Estos datos se han obtenido de forma horaria proporcionados por el satélite SARAH 2.

Los datos de PVOutput se descargan mediante su API. El procedimiento para descargarlos es introducir la dirección de la página web, donde hay que añadir el identificador de tu instalación fotovoltaica “sid” y la clave “key” (proporcionados al hacer una donación al sistema), el identificador de la planta de la que se desean descargar los datos, y el día del que se desean los datos. Como para este trabajo se requerían datos de varios años, se ha desarrollado un código en Python en el que se itera a lo largo de todos los días desde el 9 de marzo de 2015 hasta el 16 de diciembre de 2018, se introdujese el día en la dirección de la página web y los datos se fuesen almacenando en una variable hasta completar la radiación solar cada 15 minutos durante los casi 4 años de estudio, teniendo en cuenta que la API de PVOutput solamente admite 300 llamadas en una hora, por lo que se introduce en el código una instrucción para que espere una hora cuando la ejecución dé error, y a continuación, vuelva a ejecutarse. Posteriormente, estos datos serán procesados para poder entrenar la red neuronal con ellos.

Respecto a la descarga de datos de radiación solar y atmosféricos de PVGIS para la red neuronal utilizada en el artículo, el proceso consiste en introducir en la página de PVGIS [1] la ubicación exacta del lugar donde se quieren descargar los datos, en este caso la planta de Ona Solar Mercat del Carmel, la frecuencia con la que se desean descargar estos datos (horaria para este estudio), la base de datos de la que se quieren descargar (SARAH 2), el rango temporal deseado (desde 2015 a 2018, ambos incluidos), la orientación y la inclinación. Tras introducir estas instrucciones, se procede a descargar un archivo CSV que será leído mediante el código desarrollado en Python haciendo uso de la librería *Pandas*. Por otro lado, de cara a desarrollar la red neuronal convolucional, no es suficiente con obtener los datos atmosféricos de la localización de la instalación fotovoltaica, se han de descargar los datos de un mapa cuadrado con centro en la planta solar. En este caso, se han obtenido datos de un cuadrado de 81 kilómetros cuadrados

de superficie, dado que un tamaño mayor implicaba entrar en el mar y ahí no se encuentran disponibles los datos de radiación. Para realizar esto, se han tomado datos cada 0,01° de latitud y longitud, lo que corresponde a aproximadamente 1,1 kilómetros a la latitud a la que nos encontramos. Por tanto, ha sido necesario descargar los datos atmosféricos y de radiación entre 2015 y 2018 para 81 localizaciones distintas; lo cual se ha realizado mediante el desarrollo de un código que llama a la API de PVGIS y almacena los datos de todas las ubicaciones.

### 3.2.2. Procesamiento de datos

#### 3.2.2.1 PVOutput

Respecto a los datos de producción de la instalación solar, tras desarrollar el código para descargar todos los datos en las fechas deseadas, el primer paso es comprobar que no falten fechas en la colección de datos creada, un proceso no trivial debido a la gran cantidad de datos tratados. Para ello, se ha desarrollado una lista en Python que contiene todas las fechas cada 15 minutos desde el 9 de marzo de 2015 a las 14:15, hasta el 16 de diciembre de 2018 a las 23:45. Se ha procedido a comparar las longitudes de los datos descargados con esta lista y se observa que hay una diferencia de 2354 datos de los 132327 que debería haber, por lo que se descubre que faltan un 1,78 % de los datos. Para obtener estos datos, se calcula en primer lugar cuáles faltan, comparando la lista descrita anteriormente con todas las fechas y horas, y la columna del *dataframe* descargado de PVOutput que indica la fecha y hora de los datos obtenidos (para ello se realizan diversas operaciones con cadenas para que estén exactamente en el mismo formato y poder compararlas). Posteriormente, se unen las dos listas con las fechas disponibles y las que faltan en el mismo conjunto de datos y se procede a interpolar los datos que faltan mediante una interpolación lineal.

Este proceso de interpolación inevitablemente introduce ruido en el conjunto de datos, lo cual afectará a las predicciones, pero, dado que las horas sin datos representan solamente un 1,78 % del total, no supone una gran imprecisión. Para llevar a cabo esta interpolación se desarrolla un código que tiene en cuenta el número de huecos en blanco seguidos entre dos fechas y divide la diferencia entre los dos datos disponibles entre el número de huecos y asocia a cada hueco el valor correspondiente a la interpolación lineal; teniendo en cuenta que en valores como la energía que se acumula a lo largo del día, si el siguiente valor disponible es del día siguiente no se puede interpolar directamente, sino que habría que interpolar hasta las 00:00 del día siguiente y comenzar otra interpolación para el siguiente día. Una vez interpolados los datos, se grafican los originales y los interpolados para comprobar que tienen la misma forma y la interpolación se ha realizado correctamente con las cinco columnas que componen los datos de producción: energía [kWh], eficiencia[kWh/kW], potencia[W], media[W], normalizado[kW/kW].

A continuación, dado que los datos descargados se encuentran en horario español, es necesario cambiar el horario a UTC, el horario más utilizado internacionalmente y en el que se encuentran los datos de radiación. Para ello se desarrolla un código teniendo en cuenta que durante el horario de verano (desde el último domingo de marzo de cada año hasta el último domingo de octubre), España está en el horario UTC +2 y en el horario de invierno (resto del año) España se encuentra en el horario UTC+1. Por tanto, dependiendo del año y de la fecha en la que se encuentre hay que restar una o dos horas a los datos obtenidos.

### 3.2.2.2 PVGIS

En cuanto a los datos de PVGIS, el procedimiento es menos laborioso ya que los datos se encuentran en UTC y no falta ninguna fecha. Sin embargo, en el artículo a replicar se utilizan datos de radiación cada 5 minutos obtenidos de distintos satélites, y para la realización de este trabajo solamente se ha podido contar con un satélite que proporciona datos cada hora, por lo que se ha procedido a interpolar los datos para tener cada 5 minutos. Se han interpolado los datos tanto de radiación directa, como difusa, reflejada, velocidad del viento, temperatura y altura del Sol. También se ha procedido a dibujar los resultados originales y los interpolados para comprobar que la interpolación sea correcta. En las siguientes figuras se pueden observar una gráfica de la radiación directa obtenida y otra de la radiación directa interpolada.




Figura 3.17: Datos de la radiación directa descargados con frecuencia horaria




Figura 3.18: Datos de la radiación directa interpolados con frecuencia cinco-minutal

Por último, se eliminan los datos de PVGIS desde el uno de enero de 2015 hasta el 9 de marzo de 2015 a las 13:15, y entre el 16 y el 31 de diciembre de 2018, ya que no disponemos de



datos de la producción fotovoltaica en ese intervalo.

### 3.3. Criterios de evaluación de los resultados

Para poder extraer información de un modelo y que este sea de utilidad es necesario tener una referencia para compararlo con otros modelos y poder analizar su funcionamiento. Además, en este trabajo, es especialmente importante estudiar detenidamente cómo medir los errores obtenidos en la predicción para poder compararlos con los artículos del estado del arte y discutir las mejoras producidas.

Se trabaja con dos métricas para analizar los errores, el error cuadrático medio (MSE) y el error medio absoluto (MAE) que son las métricas más utilizadas para analizar los errores de los artículos analizados y, por tanto, los que se utilizarán para comparar con el resto de artículos. Las ecuaciones de los errores se presentan a continuación. El MSE (1) mide el promedio de los errores elevados al cuadrado, es decir, la media de las diferencias entre el valor predicho y el real elevados al cuadrado. El hecho de que estén elevados al cuadrado implica que el valor obtenido siempre es positivo y que si la diferencia entre ambos valores es mayor que uno, el error alcanzará un valor aún mayor y, si la diferencia es menor que 0, el error será aún menor. Por tanto, cabe esperar que en un buen modelo, este error sea reducido.

$$MSE = \frac{1}{N} \sum_{i=1}^N (Y_i - \hat{Y}_i)^2 \quad (1)$$

Por otro lado, el MAE (2) mide el promedio de la diferencia en valor absoluto del valor predicho y el real. Como consecuencia, si la diferencia entre los dos valores es menor que uno, se obtendrá un error mayor que utilizando el MSE.

$$MAE = \frac{1}{N} \sum_{i=1}^N |Y_i - \hat{Y}_i| \quad (2)$$

En estas expresiones, “N” representa el número total de predicciones que se realizan con los datos, “i” hace referencia a cada paso o predicción realizada, “Y” el valor real en el paso “i”, e “ $\hat{Y}$ ” el valor predicho en ese mismo paso.

Además de conocer las métricas de los errores, es imprescindible analizar qué valores se introducirán como el “Y” e “ $\hat{Y}$ ”. Si se toma directamente el valor de la energía producida en ese intervalo, el error será elevado, ya que un valor típico de energía durante un día soleado es 10 000 Wh, por lo que una predicción de 9 900 Wh utilizando el MSE daría lugar a un error de 10 000, es decir, un 1 000 000 % de error. Por tanto, para tener una referencia de este error, se utilizan valores de la producción energética normalizados. Para ello, se divide la cantidad de energía (Wh) producida, en el intervalo de 15 minutos dividiendo entre 4, de manera que se obtiene la potencia producida en 15 minutos (W) y esta energía se divide entre la capacidad máxima de potencia de la instalación fotovoltaica (43 740 W), de manera que siempre se obtiene un número entre 0 y 1, indicativo de la energía producida.

Por tanto, utilizando como métricas el MSE y el MAE, y datos de la producción normalizados, se pueden comparar los resultados de los modelos obtenidos con otros del estado del arte y con

el artículo a replicar, posteriormente mejorado.

## 4. RESULTADOS Y DISCUSIÓN

### 4.1. Modelos de Redes Neuronales

#### 4.1.1. Réplica del artículo

En este apartado se procede a detallar los principales modelos desarrollados para replicar el artículo [7] y las conclusiones que se obtienen de ellos. No se detallan todos ya que se han probado más de cuarenta modelos y detallarlos todos excede el objetivo de este documento.

En primer lugar, procede explicar las variables a modificar en un modelo de redes neuronales para asimilar la cantidad de alternativas distintas que se pueden probar, que son prácticamente ilimitadas.

##### 4.1.1.1 Datos de entrada de radiación y atmosféricos

Las diferentes alternativas en cuanto a los datos de entrada a introducir en el modelo referentes a la radiación y datos atmosféricos son tan influyentes en los resultados como numerosas. En este trabajo se han probado diferentes modelos tomando como entrada simplemente los datos de radiación y también tomando la radiación junto a los datos atmosféricos (velocidad del viento, temperatura y altura del sol). A su vez, la radiación se puede tomar simplemente tomando su valor total, o sus componentes descompuestas (directa, difusa y reflejada). Por tanto, se puede tomar como datos de entrada la radiación total con las distintas combinaciones de datos atmosféricos (no tomarlos, solamente la temperatura, tomar todos, etc.), la radiación dividida en sus componentes junto con las diferentes combinaciones de datos atmosféricos, etc.

##### 4.1.1.2 Datos de entrada de la producción

La introducción de la producción en los 15 o 30 minutos anteriores a la predicción resulta un dato muy relevante para el modelo, ya que la producción no suele experimentar cambios bruscos en un periodo de tiempo tan reducido. Sin embargo, también es objeto de estudio de este trabajo analizar las respuestas de los modelos a los cambios atmosféricos, por lo que se han desarrollado modelos introduciendo la producción anterior como dato de entrada (tienen un error considerablemente menor) y modelos sin introducir la producción anterior como dato de entrada.

##### 4.1.1.3 Frecuencia de los datos de entrada

Tiene una gran influencia en los resultados tomar datos de radiación en los 5 minutos previos a la predicción, en los 30 minutos previos o en la hora anterior. De la misma manera sucede con los datos de entrada de la predicción. Además, también se puede variar los intervalos en los que se proporcionan esos datos, es decir, se pueden tomar datos de los 30 minutos anteriores cada 15 minutos (2 entradas), cada 5 minutos (6 entradas) y así sucesivamente. En este trabajo se

han estudiado dos alternativas en cuanto a los datos de producción: tomar la producción en los 15 minutos previos a la predicción o en los 15 y 30 minutos previos. Sin embargo, en cuanto a los datos atmosféricos y de radiación se han probado 7 alternativas diferentes:

- I Datos atmosféricos y de radiación de la hora previa cada 15 minutos en 4 entradas.
- II Datos atmosféricos y de radiación de la hora previa cada 5 minutos en 12 entradas.
- III Datos atmosféricos y de radiación de los 30 minutos previos cada 5 minutos en 6 entradas.
- IV Datos atmosféricos y de radiación de la hora y media previa cada 5 minutos en 18 entradas.
- V Datos atmosféricos y de radiación de las dos horas previas cada 5 minutos en 24 entradas.
- VI Datos atmosféricos y de radiación de las dos horas y media anteriores cada 5 minutos en 30 entradas.
- VII Datos atmosféricos y de radiación de las tres horas previas cada 5 minutos en 36 entradas.

#### 4.1.1.4 Estructura de la red neuronal

Las redes neuronales pueden seguir todo tipo de estructuras, ya que, entre otros parámetros, se puede variar: el número de capas de la red neuronal, el tipo de capas, el número de neuronas de cada capa, la función de activación de cada capa y en qué capa de la red introduces cada tipo de dato. En este caso, se han probado distintas variaciones, pero se ha optado por seguir mayoritariamente una estructura consistente en:

- I Una capa oculta para cada entrada donde se procesan las tres dimensiones de la radiación.
- II Una capa que concatena las capas ocultas de las entradas y, si los hubiese, los datos atmosféricos y producción.
- III Dos capas ocultas adicionales.
- IV Una capa de salida.

En cuanto al número de neuronas por cada capa, se ha procedido a probar con cuatro alternativas, de las cuales, tres han sido reproducidas del artículo [7]. Se presentan a continuación:

- Una neurona por cada capa: es un modelo trivial, utilizado en las primeras experimentaciones con datos nuevos para confirmar que el funcionamiento fuese correcto antes de realizar cálculos más complejos.
- Primera fórmula de neuronas: un modelo con un número de neuronas bajo, interesante para analizar el comportamiento y evitar el sobreajuste de la red neuronal a los datos de entrenamiento y un mal comportamiento en los datos de validación.  $Neuronas = \frac{2}{3}(In + Out)$ .
- Segunda fórmula de neuronas: un modelo con un número de neuronas parecido, pero mayor. Tiene un buen funcionamiento, ya que este aumento de neuronas permite mejorar la complejidad del modelo, a la par que esta no es demasiado grande por lo que no requiere un tiempo de ejecución muy elevado, ni una gran carga computacional  $Neuronas = \frac{3}{2}(In + Out)$ .

- Tercera fórmula de neuronas: un número de neuronas considerablemente más elevado, suele tener un buen comportamiento, debido a que el aumento de complejidad permite ajustarse más a los datos y crear salidas más complejas. Su principal inconveniente es el elevado tiempo de ejecución.  $Neuronas = \frac{1}{2}(In + Out) + \sqrt{Training}$ .

Donde,  $In$  es el número de elementos o dimensiones de la entrada a la capa,  $Out$  es el número de elementos o dimensiones de la salida a la capa y  $Training$  es el número de muestras.

### 4.1.1.5 Cantidad de datos de entrenamiento y validación

El rango temporal de los datos que se toman también supone un punto de inflexión en los modelos. Para este proyecto se han descargado todos los datos disponibles de la instalación solar fotovoltaica, que son datos de la producción cada 15 minutos desde el 9 de marzo de 2015 a las 13:15 hasta el 16 de diciembre de 2018 a las 22:45 (en UTC), lo que supone un total de 132343 fechas distintas de las que se disponen de datos de producción. A su vez, se dispone de los datos atmosféricos y de radiación en las mismas fechas, pero con frecuencia de cada 5 minutos, por lo que el número total de fechas distintas asciende a 396979. Siendo estos todos los datos disponibles para el entrenamiento y la validación, se ha decidido hacer una división del 80 % de los datos para entrenar los modelos y se ha reservado el 20 % para validarlos una vez entrenados. No se ha tomado un conjunto de datos *test* debido a que, al no tener demasiados datos, es conveniente tener el mayor número de datos posibles para el entrenamiento y además, a que el primer objetivo es reproducir los datos del artículo [7], en el cuál solamente presentan datos de entrenamiento y validación.

### 4.1.1.6 Parámetros de la ejecución

Para ejecutar los modelos se ha decidido tomar como optimizador *Adam* de la librería Keras, un método de optimización basado en el descenso del gradiente frecuentemente utilizado en la literatura para este tipo de problemas. Definido como: “[...] eficiente desde el punto de vista computacional, tiene pocos requisitos de memoria, es invariable ante el cambio de escala diagonal de los gradientes y se adapta bien a los problemas que son grandes en términos de datos/parámetros” [20]. Además, se ha tomado como función de pérdidas, la función a optimizar, el error cuadrático medio (MSE) y se ha establecido un criterio de parada con paciencia 15 monitorizando la función de pérdidas del conjunto de validación, es decir, termine de entrenarse el modelo cuando hayan pasado 15 épocas desde la última mejora del error cuadrático medio evaluado sobre los datos de validación.

### 4.1.1.7 Modelos

#### Modelo 5

Este modelo es uno de los primeros modelos realizados en el que se produce un buen entrenamiento de la red neuronal. Esta red neuronal consiste en cuatro entradas que aportan a la red los datos de la radiación solar de la hora anterior a la predicción con datos cada 15 minutos hasta el momento de la predicción. Se utiliza la segunda fórmula del número de neuronas por cada capa:  $Neuronas = \frac{3}{2}(In + Out)$ . La estructura de la red consiste en una capa oculta para

cada entrada con 6 neuronas cada una, de manera que se procesen las tres dimensiones de la radiación, una capa que concatena las capas ocultas, otras dos capas ocultas adicionales con 3 neuronas cada una y una capa de salida con 2 neuronas. Cabe mencionar que los datos de salida la producción solar que utiliza el modelo para calcular el error se introducen divididos por su desviación típica como técnica de normalización, al igual que los datos de radiación y atmosféricos. En la siguiente figura se puede observar la evolución del error cuadrático medio (MSE) en los datos de entrenamiento y validación conforme aumenta el número de épocas, hasta que se produce la parada tras 15 épocas sin descender el MSE en los datos de validación.




Figura 4.1: Evolución del MSE en los datos de entrenamiento y validación en el Modelo 5

En la época número 41 se alcanza un MSE de 0,4773 en los datos de entrenamiento y 0,4479 en los datos de validación, que es un error muy alto, ya que faltan datos relevantes para la predicción, pero se observa el entrenamiento de la red neuronal. A continuación, se estudia cómo se puede mejorar el modelo, se lleva a cabo otro modelo utilizando un mayor número de neuronas en cada capa (la tercera fórmula) y se obtienen resultados muy similares con mucho mayor tiempo de computación. Como consecuencia se decide construir un nuevo modelo introduciendo datos que incluyan los valores atmosféricos, no solamente la radiación.

**Modelo 8** Se utiliza una red neuronal con la misma estructura que en el modelo 5, pero se entrena también con datos atmosféricos, como se ha mencionado anteriormente, y con mayor número de neuronas por cada capa, porque al aumentar la complejidad de los datos de entrada, se decide aumentar también la complejidad del modelo. Se utiliza la tercera fórmula del número de neuronas por cada capa:  $Neuronas = \frac{1}{2}(In + Out) + \sqrt{Training}$ , dando lugar a un número aproximado de 365 neuronas por cada capa (varía un poco con cada capa al cambiar la dimensión de las entradas). De la misma manera, se presenta la evolución del error cuadrático medio (MSE) en los datos de entrenamiento y validación conforme aumenta el número de épocas, hasta que se produce la parada tras 15 épocas sin descender el MSE en los datos de validación.




Figura 4.2: Evolución del MSE en los datos de entrenamiento y validación en el Modelo 8

Como se puede observar, se obtiene un MSE sobre los datos de entrenamiento de 0,3385 y un MSE sobre los datos de validación de 0,3268 en 35 épocas, resultados claramente mejores a los obtenidos en el modelo 5.

El proceso de mejora de modelos continúa, estudiándose diferentes alternativas y cambiando los parámetros que influyen en el entrenamiento y predicción de las redes neuronales hasta llegar al modelo 31.

**Modelo 31** Este modelo utiliza datos de entrada de la radiación descompuesta en sus componentes y de los factores atmosféricos sin tener en cuenta la velocidad del viento, porque se ha probado que el error es menor cuando no se tiene en cuenta. Estos datos se introducen de las tres horas anteriores a la producción con una frecuencia de 5 minutos, por lo que entran a la red 36 entradas, siguiéndose la estructura descrita anteriormente. Además, se utiliza la tercera fórmula del número de neuronas por cada capa, y los datos de salida de la producción con los que se compara el error se introducen normalizados, pero en vez de dividirlos entre la desviación típica, se divide la potencia generada en los 15 minutos de estudio entre la potencia máxima de la instalación fotovoltaica. Esto da lugar a la evolución del error y sus valores mostrada en la siguiente figura.




Figura 4.3: Evolución del MSE en los datos de entrenamiento y validación en el Modelo 31



La red neuronal no experimenta un gran entrenamiento, pero se alcanza un error muy reducido: un MSE en los datos de validación de 0,0152 y un MAE de 0,0739 medido sobre el mismo conjunto de datos. Dado que en el artículo a replicar [7], se alcanza un MSE de 0,040 y un MAE de 0,161 utilizando información de la radiación 4 satélites distintos y de 4 instalaciones fotovoltaicas distintas, se sospecha que han podido utilizar un conjunto de datos distintos. Tras investigar los artículos que citan, se llega a la conclusión de que han podido predecir solamente datos durante el día, ya que es lo que interesa porque por la noche no se produce energía, lo que hace que el error disminuya al ser más fácilmente predecible. Por tanto, se desarrolla un nuevo modelo igual al 31, pero utilizando datos solamente durante el día.

### Modelo 32

En este nuevo modelo se replica exactamente la red neuronal del modelo 32, variando solamente los datos. Se utilizan datos de entrada solamente durante las horas del día, entre las 6:00 y las 22:00, y se predice la producción en este mismo rango horario, obteniéndose los errores descritos a continuación.




Figura 4.4: Evolución del MSE en los datos de entrenamiento y validación en el Modelo 32

La red neuronal alcanza los mejores resultados en el conjunto de validación tras entrenar durante 3 épocas. Los errores obtenidos son, sobre el conjunto de validación, un MSE de 0,0673 y un val MAE de 0,2357. Estos resultados son muy semejantes a los del artículo, ligeramente peores, pero este empeoramiento es completamente esperable por los factores expuestos anteriormente relativos a la calidad de los datos utilizados.

Como consecuencia, se concluye este modelo como una réplica del modelo vanguardista utilizado en el artículo [7]. A modo de recopilación, la red neuronal utilizada consta de 36 entradas que contienen la información correspondiente a la radiación solar descompuesta en sus 3 componentes en las 3 horas previas a la predicción y con una frecuencia de 5 minutos. Asimismo, dispone de otras 36 entradas que transmiten los datos atmosféricos de la temperatura y la altura del Sol en las 3 horas previas a la predicción y con una frecuencia de 5 minutos. Las entradas de la radiación se introducen en 36 capas ocultas de 365 neuronas cada una y, cada una de estas capas se añade como entrada a una capa que las concatena junto con las otras 36 entradas de los datos atmosféricos. A continuación, la salida de esta capa se introduce en una capa oculta de 364 neuronas y, esta salida, a otra capa oculta. Finalmente, se introduce esta salida como entrada en la última capa de salida, dando lugar a unos errores sobre el conjunto

de validación de un  $MSE = 0,0673$  y  $MAE = 0,2357$ .

### 4.1.2. Mejora del modelo

#### 4.1.2.1 Introducción de la producción

De cara a mejorar el modelo 32 se procede a utilizar dos enfoques distintos. En primer lugar, introducir como dato de entrada la producción anterior lo cual se espera que mejore rápidamente el modelo debido a que los valores de la producción en horas tan próximas se espera que sean muy similares. El segundo enfoque es la creación de un algoritmo de redes neuronales convolucionales para utilizar los datos de radiación, no solamente de la ubicación de la instalación fotovoltaica, sino de un área de 91 kilómetros cuadrados en cuyo centro se ubica la planta.

Se prueban los mejores modelos utilizados en el apartado anterior, utilizando los datos solamente de día y añadiéndoles datos de entrada de la producción en los 15 minutos y en los 30 minutos anteriores cada 15 minutos, ya que son los datos de los que disponemos. Es decir, se añaden 1 ó 2 nuevas entradas con la producción anterior normalizadas según la capacidad máxima de la planta fotovoltaica. Tras desarrollar distintos modelos, presentamos el que mejor comportamiento tiene.

#### Mejor modelo con producción

Los datos de entrada al modelo consisten en 36 entradas con la radiación dividida en sus componentes y otras 36 los datos atmosféricos relevantes (temperatura y altura del Sol) en las 3 horas previas a la predicción con una frecuencia de 5 minutos, además de 2 entradas con la producción 15 y 30 minutos antes. Los datos atmosféricos y de radiación se estandarizan dividiendo entre su desviación típica, mientras que los de la producción se normalizan respecto a la capacidad máxima de la instalación fotovoltaica. La estructura del modelo consiste, de nuevo, en 36 capas ocultas donde se introducen los datos de radiación descompuestos en sus componentes, una capa que concatena estas 36 capas ocultas más las 36 entradas de datos atmosféricos y las 2 de producción. A continuación, la salida de esta capa se introduce en otra capa oculta y su respectiva salida a otra capa oculta más, que va a parar a una última capa de salida, produciéndose el resultado. Se ha utilizado la función de activación ReLU en todas las capas y el número de neuronas se ha calculado con la segunda fórmula:  $Neuronas = \frac{3}{2}(In + Out)$ . La función de pérdidas a optimizar con el método *Adama* es el error cuadrático medio y se ha ejecutado hasta que no se han producido mejoras en el MSE evaluado en los datos de validación durante 15 épocas consecutivas. Las siguientes figuras representan la evolución del MAE y MSE, respectivamente, en los conjuntos de entrenamiento y validación durante las 40 épocas en las que se ha entrenado.




Figura 4.5: Evolución del MAE evaluado en los datos de entrenamiento y validación




Figura 4.6: Evolución del MSE evaluado en los datos de entrenamiento y validación

El valor más bajo del MSE en el conjunto de validación se da en la época 25 y tiene un valor de 0,0045, siendo el valor del MAE en esta misma época de 0,0392, lógicamente un valor superior ya que el error no se eleva al cuadrado. Comparando estos resultados con el modelo sin producción observamos la notable mejoría en la predicción introduciendo datos de la producción, ya que estos valores eran un MAE de 0,2357 y un MSE de 0,0673. El error se ha reducido a menos de una décima parte.

#### 4.1.2.2 Red Neuronal Convolutiva

El segundo enfoque utilizado para mejorar la previsión de la energía solar fotovoltaica se basa en el uso de un tipo de red neuronal completamente diferente a los utilizados anteriormente en este trabajo. Permite procesar datos de radiación en un área alrededor de la planta solar, en vez de restringirse a su localización, por lo que es de esperar que sea de mayor utilidad ante cambios repentinos en el tiempo atmosférico. El uso de las tres componentes de la radiación como datos

de entrada en los momentos previos a la predicción en un área determinada es comparable al uso de una imagen a color con sus tres componentes de color: rojo, verde y azul (RGB en inglés); mientras que si utilizamos estos datos de toda la hora previa a la predicción se asemeja a utilizar un vídeo con la radiación, siguiendo la misma analogía.

Para llevar esto a cabo, tras obtener los datos necesarios, se desarrollan e implementan distintos modelos de redes neuronales convolucionales progresivamente, desde modelos más triviales hasta más complejos. Como se ha mencionado en el desarrollo teórico, una limitación muy grande para este tipo de redes neuronales es la carga computacional, ya que requiere el uso de una cantidad de datos muy superior a las redes neuronales utilizadas anteriormente, por lo que la memoria del ordenador se consume y requiere un tiempo de cálculo mucho mayor, esto es especialmente perjudicial cuando se utiliza un ordenador no preparado para este tipo de operaciones.

Inicialmente, se realizan una serie de modelos de redes neuronales convolucionales en 2D, es decir, introduciendo datos de la radiación en el área de 9 km x 9 km en un único instante temporal, en los 15 minutos previos a la predicción.

### **Primer Modelo Convolutivo 2D**

El primer modelo convolutivo que entrena y obtiene resultados positivos, consiste en tres capas convolucionales de 8 neuronas con filtros de tamaño (3,3) y función de activación *ReLU*. Dado que los datos de entrada al modelo tienen un tamaño de (9,9) del mapa, al aplicar cada capa convolutiva con filtros del tamaño descrito, reducen su tamaño en dos por cada dimensión, por lo que tras la primera capa convolutiva el tamaño será (7,7), tras la segunda será de (5,5) y tras la tercera de (3,3). Posteriormente esta salida se introducirá en una capa *Flatten*, cuya función es 'aplanar' la entrada de manera que pase a tener una sola dimensión, para conectar la capa convolutiva a una completamente conectada. La próxima capa es una capa oculta de 15 neuronas y función de activación *ReLU* y, finalmente, una capa de salida con una neurona. El modelo se compila siguiendo los parámetros descritos en apartados anteriores, se emplea el optimizador *Adam*, que minimiza la función de pérdidas, el error cuadrático medio, y la ejecución finaliza cuando después de 15 épocas no ha mejorado el MSE evaluado en los datos de validación, que representan un 20 % de los datos totales, siendo los de entrenamiento el otro 80 % restante. Se representa en la figura que se muestra a continuación, la evolución del MSE en este modelo.




Figura 4.7: Evolución del MSE en los datos de entrenamiento y validación en el modelo convolucional 1

Se observa que la red neuronal convolucional no entrena satisfactoriamente, ya que el error cuadrático medio obtenido en los datos de validación es muy oscilante y no sigue una progresión descendente a lo largo de las épocas. Aún así, se obtienen errores bajos, un MSE de 0.0667 y un MAE de 0,2232 calculado sobre los datos de validación.

### Mejor modelo convolucional 2D sin producción

Tras desarrollar diferentes modelos de redes neuronales convolucionales en 2D modificando las distintas variables que intervienen, como introducir una capa *dropout* para evitar el sobreajuste, se ha llegado a la conclusión de que el modelo con mejor funcionamiento incluye una capa *concat* adicional al modelo anterior después de la capa oculta, en la que se aúna la salida de esta capa con la media de los datos atmosféricos de las distintas localizaciones del mapa. No se introducen estos datos atmosféricos de todas las localizaciones porque son muy parecidos entre sí por estar en una misma zona de proximidad y al ser un número tan grande de datos, podrían introducir ruido en el modelo sin aportar nada nuevo. A continuación de esta capa de concatenación se añade otra capa oculta con 15 neuronas, previa a la capa de salida. Los filtros de las capas convolucionales se mantienen con tamaño (3,3) y la función de activación de las capas también es *ReLU*. En este caso, sí que se tiene en cuenta la velocidad del viento ya que por experimentación se ha demostrado que tiene una influencia positiva.




Figura 4.8: Evolución del MSE en los datos de entrenamiento y validación en el mejor modelo convolucional 2D

De la gráfica se puede concluir que el modelo entrena, fijándose en los datos de entrenamiento, pero el error en los datos de validación es oscilante, lo cual puede indicar que está sobreajustado a los datos de entrenamiento. No obstante, los mejores resultados se obtienen en la época 7, donde el valor sobre el conjunto de validación del MSE es 0,0664 y el del MAE es 0,2234 , mejorando los resultados obtenidos al reproducir el artículo [7]. Por lo que se puede concluir que se ha logrado el objetivo de mejorar el modelo mediante el uso de redes neuronales convolucionales

### Modelo convolucional 2D con producción

Con el objetivo de comparar el mejor resultado obtenido respecto al anterior modelo y de buscar el error más reducido posible en la predicción de energía solar fotovoltaica, se desarrolla un modelo con datos de producción en los 30 minutos anteriores a la predicción mediante 2 entradas: una que introduce la producción en los 30 minutos previos y otra que la introduce en los 15 minutos previos. La estructura de la red neuronal convolucional es la misma que en el modelo presentado anteriormente, con la salvedad de que en la capa *concat* se introducen las entradas de producción mencionadas. En la siguiente figura se representan los resultados del modelo, la evolución del MSE y del MAE según la red entrena durante 24 épocas.




Figura 4.9: Evolución del MSE en los datos de entrenamiento y validación en el modelo convolucional 2D con producción




Figura 4.10: Evolución del MAE en los datos de entrenamiento y validación en el modelo convolucional 2D con producción

El modelo entrena rápidamente con los datos de entrenamiento, en los que baja velozmente el error durante las primeras épocas, pero en los datos de validación oscila, de manera que el aprendizaje es menor que en el conjunto de entrenamiento. Sin embargo, el error cometido es muy inferior al del modelo sin producción, como era de esperar, alcanzando en la novena época un MSE con un valor de 0,0043 y el MAE con valor de 0,0356. Esto deja claro que utilizando redes neuronales convolucionales y la radiación y producción en los instantes previos, se puede predecir la producción de energía solar fotovoltaica con un margen de error suficientemente bajo.

A continuación, se muestra una tabla comparativa con los resultados de los diferentes modelos desarrollados e implementados.

Errores de los modelos		
Modelo	MSE	MAE
RN1	0,0673	0,2357
RN1Producción	0,0045	0,0385
RNC	0,0664	0,2234
RNCProducción	0,0043	0,0356
Artículo_R	0,040	0,161

Tabla 4.1: Errores modelos de redes neuronales en el conjunto de validación.

Donde RN1 representa los modelos creados con redes neuronales replicando las del artículo, RNC hace referencia a los modelos de redes neuronales convolucionales y el sufijo producción señala los modelos en los que se ha utilizado la producción como dato de entrada.

De la tabla se pueden obtener dos conclusiones de forma directa: la influencia de introducir la producción como dato de entrada al modelo y el buen funcionamiento de las redes neuronales de convolución. En cuanto a la producción, se observa que el error se reduce a menos de la décima parte, por lo que si ese dato se encuentra disponible a la hora de realizar predicciones a corto plazo, se debe utilizar. Por otro lado, se ha demostrado que el empleo de redes neuronales convolucionales también mejora las predicciones. Se representa una gráfica con estos resultados con el fin de analizarlos de forma más visual, dividiéndolos en los modelos que incorporan los datos de la producción como entrada y los que no los utilizan.




Figura 4.11: Representación de los errores en los modelos sin producción.



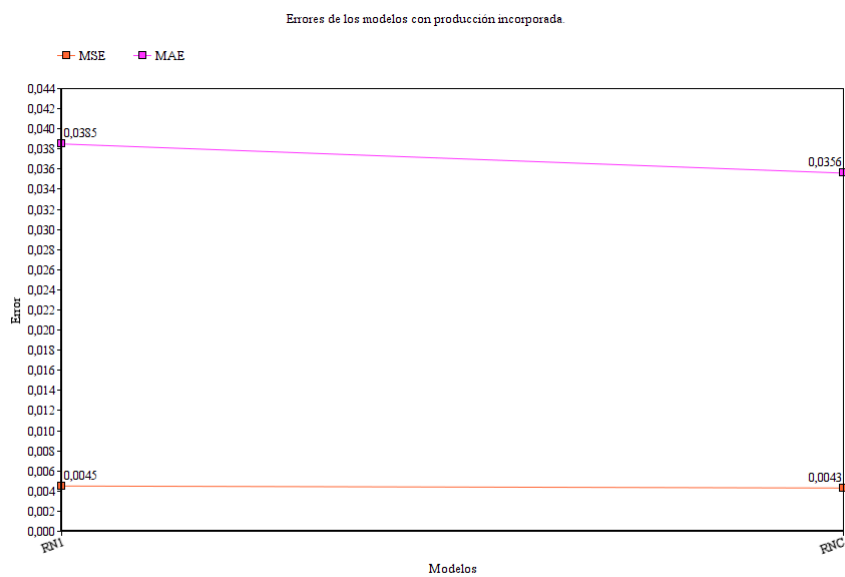


Figura 4.12: Representación de los errores en los modelos que incorporan la producción.

## 5. CONCLUSIONES

Los principales objetivos de este trabajo fueron descritos al principio del documento: replicar un modelo vanguardista y desarrollar un modelo de redes neuronales que arroje luz sobre la predicción de la producción de energía solar fotovoltaica. Tras analizar el trabajo realizado, se puede afirmar que este objetivo se ha cumplido. Se ha logrado replicar los resultados en la predicción de energía solar fotovoltaica [7], y además, mejorar estos resultados mediante dos enfoques distintos: la aplicación de otro tipo de redes neuronales completamente distinto a los utilizados en el mismo, redes neuronales convolucionales; y mediante el uso de datos de la producción anterior al momento de la predicción.

En cuanto a la réplica de los resultados obtenidos en el artículo, se ha logrado un objetivo ambicioso. En este artículo no se da demasiada información sobre los datos de entrada para entrenar la red neuronal, se ha tenido que trabajar minuciosamente en su obtención, procesado y utilización hasta dar con resultados coherentes con los del artículo estudiado. Esto ha dado lugar a la elaboración de numerosos modelos en los que se ha probado diferentes combinaciones de datos de manera progresiva y reflexiva. Se ha analizado cada modelo y sus resultados respecto a los anteriores para discernir si se estaba avanzando en la dirección correcta y cuál sería el mejor modelo que se puede realizar a partir de los existentes para obtener resultados coherentes con el artículo, sin utilizar herramientas que no hayan sido utilizadas. Tras este proceso, se han obtenido resultados satisfactorios comparando con las métricas que se utilizan en el artículo para medir el error: en él se llega a un MSE de 0,040 y a un MAE de 0,161; mientras que en este trabajo se obtiene un MSE de 0,0673 y un MAE de 0,2357 sobre los datos del conjunto de validación. El aumento en el error tiene su fundamento en que en el artículo se utilizan datos de radiación de 4 satélites diferentes y de distintas plantas fotovoltaicas, mientras que para la elaboración de este trabajo solamente se ha podido contar con datos de 1 satélite y una planta solar. Por tanto, se puede concluir como lograda la reproducción del artículo descrito.

Desde el punto de vista de la mejora, también se ha logrado con éxito un reto interesante. Se ha conseguido mejorar, no solamente mediante una técnica, sino mediante dos procedimientos diferentes. En primer lugar, introduciendo para entrenar la red neuronal datos disponibles de la producción solar en instantes anteriores a la predicción, lo cual tiene un gran efecto sobre los resultados del modelo, reduciéndose el error a menos de la décima parte, al obtenerse sobre los datos de validación un MSE de 0,0045 y un MAE de 0,0385.

Por otro lado, se ha logrado implementar una red neuronal convolucional que utiliza como datos de entrada referentes a la radiación, la radiación en un área alrededor de la planta solar, en vez de la localización exacta de la planta. Esto implica que se puede elevar la precisión de los datos de la radiación y, consecuentemente, mejorar el modelo. Utilizando este algoritmo se han alcanzado unos errores sobre los datos de validación de 0,0664 y 0,2245, referentes al MSE y MAE, respectivamente. Además, a este modelo también se le pueden introducir datos de la producción en instantes anteriores para disminuir el error, el cual, de nuevo, disminuye rápidamente al utilizar estas entradas, obteniéndose un MSE de 0,0043 y un MAE de 0,0356, también evaluado sobre el conjunto de validación.

Con las evidencias presentadas, se puede concluir que se han logrado los objetivos propuestos. A continuación se muestra un gráfico donde se pueden comparar los errores gráficamente, tanto los obtenidos incorporando la producción, como sin incorporarla.

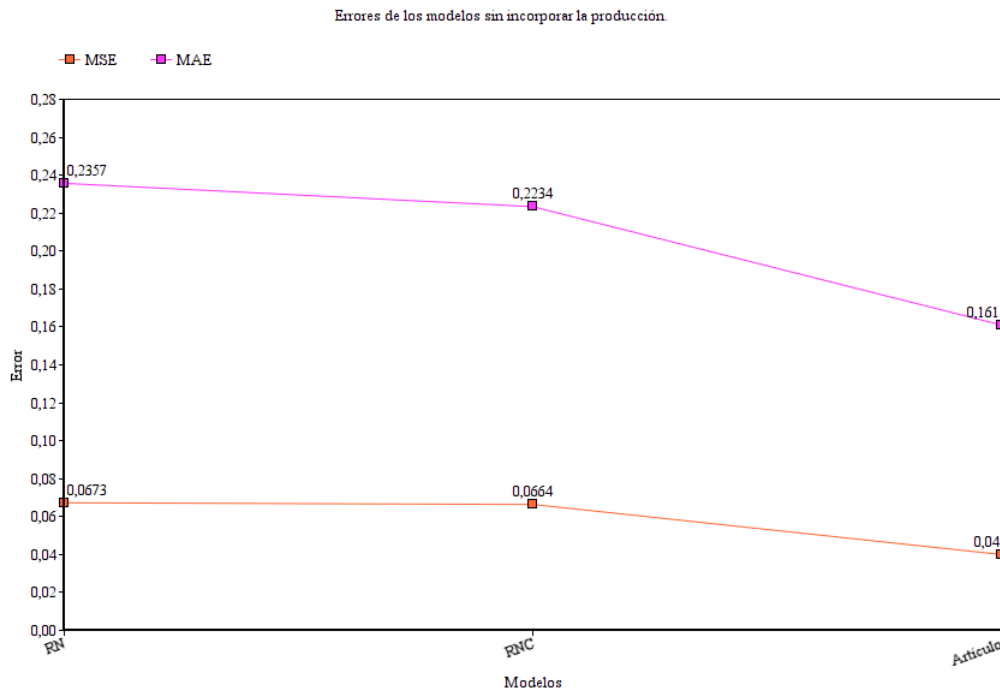


Figura 5.1: Comparativa de los errores obtenidos sin incorporar la producción.




Figura 5.2: Comparativa de los errores obtenidos al incorporar la producción.

## 6. LÍNEAS FUTURAS

Las redes neuronales están sufriendo una evolución continua, por lo que es probable que estos resultados se puedan mejorar utilizando nuevas técnicas en desarrollo. Asimismo, al ser algoritmos con tantos factores y variables influyentes, hay diversos caminos por los que se puede investigar y mejorar las redes neuronales utilizadas en este trabajo.

En primer lugar, no se ha podido implementar ningún modelo de redes neuronales de convolución en 3D debido a las limitaciones de memoria del ordenador con el que se ha llevado a cabo el proyecto y de otras herramientas de ejecución en-línea como *Google Colab*. Estas redes permiten utilizar como datos de entrada, en vez de una imagen estática con los datos de radiación en un área determinada, un conjunto de imágenes con datos de la radiación en ese área a lo largo de distintos momentos, de manera que es como introducir un vídeo con los datos de la radiación que permiten realizar predicciones con mayor precisión. El uso de las redes neuronales de convolución en 2D ha logrado una pequeña, pero relevante, reducción en el error, sin embargo se cree que la implementación de estas redes en 3D puede llevar consigo una gran mejoría.

Por otro lado, no se han podido obtener de diferentes satélites datos de la radiación, por lo que para obtener los datos requeridos cada 5 minutos, se ha tenido que interpolar datos horarios. Esto da lugar a dos problemas, primero, que se introduce ruido en los datos que se utilizan para entrenar la red neuronal, ya que no son exactos, sino aproximaciones; en segundo lugar, se utilizan datos que aún no se disponen para realizar las predicciones, ya que se han interpolado datos de instantes temporales posteriores a la predicción. Por ejemplo, para estimar la producción de energía fotovoltaica entre las 12:15 y las 12:30 se toman datos de radiación a las 12:10, sin embargo, estos datos proceden de una interpolación de los valores a las 12:00 y a las 13:00, por lo que en la práctica, no se dispone de ellos. No obstante, este trabajo no pretende crear modelos de aplicación actual, sino actuar como base teórica para arrojar luz sobre la predicción solar fotovoltaica.

Por último, siempre se puede aumentar el número de datos para mejorar los resultados. Se puede tomar un área más grande para entrenar las redes neuronales convolucionales, se puede tomar un rango temporal más elevado, etc. Además, se pueden utilizar técnicas más sofisticadas para optimizar el número de capas empleadas en cada modelo y el número de neuronas presentes en cada capa. Siempre hay lugar para la mejora.

## **7. RESPONSABILIDAD SOCIAL, AMBIENTAL Y PROFESIONAL**

La realización de este Trabajo de Fin de Grado se ha dado debido al trasfondo e importancia que tiene, atendiendo a distintos frentes, el desarrollo de la energía solar fotovoltaica, englobada en las energías renovables.

En primer lugar, debido a un factor de responsabilidad ambiental, un reto muy presente en la sociedad actual es la transición desde el uso de las fuentes de energía no renovables y contaminantes a fuentes de energía limpias y renovables. Estas fuentes de energía se encuentran inmersas en un desarrollo continuo, ya que en su estado actual no son suficientes para cubrir la demanda de energía a nivel mundial. Uno de sus principales inconvenientes es la dependencia de factores externos al ser humano, como la dependencia climática. Esto provoca que disminuya su fiabilidad y su provecho, por lo que una mejora en la capacidad predictiva de la energía solar fotovoltaica supone un paso en la dirección de sustituir las fuentes de energía no renovables por renovables.

Por otro lado, el oscilante precio de la luz está alcanzando máximos históricos en la historia de España en el tiempo de realización de este proyecto. Esto se debe a diversos motivos, pero supone un grave problema tanto para la industria como para particulares. El desarrollo de la energía solar fotovoltaica supone una ayuda a este problema, ya que se puede producir energía de forma local sin necesidad de importarla, especialmente en España que cuenta con unas condiciones atmosféricas y de radiación solar privilegiadas, por lo que se puede producir una gran cantidad de energía solar fotovoltaica. Además, debido al funcionamiento del mercado eléctrico español, unas predicciones precisas de la producción de la demanda permitirían casar mejor la cantidad de oferta y demanda, y, de esta manera, optimizar la producción y reducir costes.

## 8. PLANIFICACIÓN TEMPORAL Y PRESUPUESTO

### 8.1. Planificación temporal

Para analizar la planificación temporal del Trabajo de Fin de Grado, se va a desglosar el mismo en las distintas actividades que se han llevado a cabo para su elaboración y se va a acompañar de la Estructura de Descomposición del Proyecto y el diagrama de Gantt.

I Investigación. La primera parte del trabajo ha consistido en la lectura, asimilación y aprendizaje de distintos artículos relacionados con este proyecto. Primero, artículos relativos al funcionamiento de la energía solar fotovoltaica, la importancia del problema a resolver, información sobre diferentes parques solares, etc. Posteriormente, artículos vanguardistas sobre predicción de este tipo de energía mediante el uso de técnicas computacionales y redes neuronales, para aprender de ellos y enfocar correctamente el trabajo. Por tanto, la fase de investigación se compone de:

- Lectura de artículos y aprendizaje referente a las energías renovables y, concretamente, a la energía solar fotovoltaica.
- Aprendizaje sobre los métodos de predicción de la energía fotovoltaica y principales técnicas utilizadas en la industria.
- Análisis de artículos vanguardistas y los métodos de implementación de redes neuronales para hacer frente a problemas de predicción de energía solar fotovoltaica.

II Descarga y procesamiento de datos. Esta ha sido la parte más laboriosa y duradera del trabajo, ya que abarca la creación de código elaborado en *Python* para obtener datos de dos fuentes distintas, y su procesamiento para poder utilizarlo para entrenar la red neuronal con el menor ruido posible. Se puede descomponer en:

- Desarrollo de código para la descarga de datos desde la API de PVOutput, la fuente de los datos de producción de la instalación fotovoltaica.
- Tratamiento de los datos de producción para su uso. Incluye la comprobación de los datos vacíos, interpolación de los necesarios, etc.
- Desarrollo de código para la descarga de datos desde la API de PVGIS, la fuente de los datos de radiación solar y factores atmosféricos.
- Tratamiento de los datos atmosféricos para su uso.

III Creación y desarrollo de los modelos de redes neuronales. Este proceso ha consistido en una prueba reflexiva de distintos modelos hasta encontrar el que mejor se comportaba para cumplir los objetivos del trabajo. Esta fase está compuesta por:

- Reproducción del modelo del artículo [7].
- Creación de nuevos modelos añadiendo datos de la producción fotovoltaica en horas anteriores.
- Creación de nuevos modelos de redes neuronales convolucionales.

IV Análisis de los resultados. En esta parte del proyecto se ha procedido a comparar los resultados obtenidos con otros artículos, analizar si cumplen los objetivos propuestos y llegar a conclusiones basadas en los resultados de los modelos.

V Redacción de la memoria. Una vez obtenidos los resultados y las conclusiones, se ha procedido a redactar y detallar el proceso seguido, sus resultados y conclusiones, de manera que se pueda comprender el trabajo realizado y cumplir con su cometido. Para ello se han seguido las siguientes actividades:

- Aprendizaje sobre la utilización de Latex y su extensión en línea *Overleaf*.
- Redacción de los distintos apartados de los que se compone la memoria.
- Elaboración de detalles para facilitar la comprensión, como tablas, gráficos, etc.

VI Defensa del Trabajo de Fin de Grado.

- Análisis de la audiencia de la exposición del trabajo y la posición del orador frente a ella.
- Reflexión sobre las partes del trabajo más importantes a la hora exponer para ajustarse al tiempo establecido.
- Elaboración de un guión con los conceptos a presentar.
- Creación de la presentación a utilizar.
- Presentación del Trabajo de Fin de Grado ante el tribunal.

**Diagrama de Gantt** A continuación se presenta el diagrama de Gantt del proyecto, con la distribución temporal del tiempo dedicado a cada fase del mismo.




Figura 8.1: Diagrama de Gantt del proyecto

**Estructura de Descomposición del Proyecto** Se añade la EDP del proyecto en la que se plasman las diferentes fases que componen el Trabajo de Fin de Grado

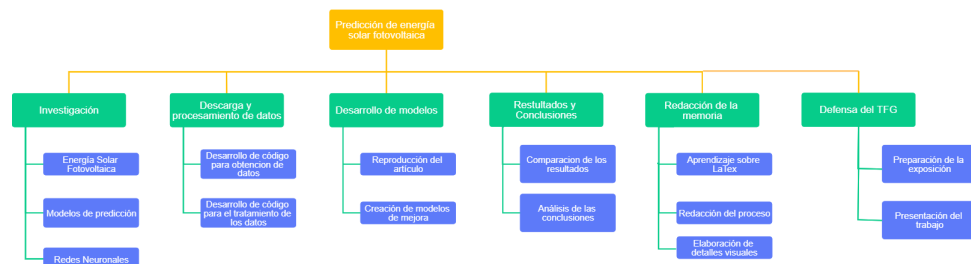


Figura 8.2: Estructura de Descomposición del Proyecto

## 8.2. Presupuesto

En este apartado del proyecto se lleva a cabo un análisis del coste económico ocasionado por la realización de este Trabajo de Fin de Grado. Se analizan los costes materiales, los costes humanos y, por último, se calcula el coste total de la elaboración del trabajo.

En cuanto a los costes materiales, se presenta una tabla con estos costes descompuestos, teniendo los costes del equipo y material utilizado, además del coste de licencias necesarias en términos de software para la ejecución. Asimismo, se tiene en cuenta la amortización de un quinto del ordenador personal durante la realización del trabajo.

Concepto	Importe	Amortización	Coste
Ordenador	700	20 %	104
Látex - Overleaf	0	-	0
Jupyter Notebook	0	-	0
Google Colab	0	-	0
Spyder	0	-	0
PVOutput	15	-	15
TOTAL			119

Tabla 8.1: Costes Materiales

El cálculo de los costes de recursos humanos se ha basado en el tiempo utilizado en el desarrollo completo del proyecto, por parte del alumno y del tutor. Para estos cálculos se ha tomado una retribución por parte del tutor de 30€/h, mientras que para el alumno esta se considera de 15€/h. A continuación se expone una tabla con estos costes descompuestos.

Concepto	Unidades	Precio unitario	Coste
Reuniones con el tutor	15	30	450
Reuniones con el alumno	15	15	225
Documentación bibliográfica	60	15	900
Programación	100	15	1500
Análisis de los resultados	65	15	975
Redacción de la memoria	55	15	825
Revisión de la memoria	5	30	150
TOTAL			5025

Tabla 8.2: Costes de Recursos Humanos

**Costes totales** Por último, se suman ambos costes para obtener los costes totales del proyecto.



Concepto	Coste
Recursos Materiales	119
Recursos humanos	5025
Impuestos (IVA)	1080.24
Total	6224.24

Tabla 8.3: Costes Totales

El coste total después impuestos representa un total de:

**SEIS MIL DOSCIENTOS VEINTICUATRO EUROS CON VEINTICUATRO CÉNTIMOS**



## 9. BIBLIOGRAFÍA

### Referencias

- [1] Jrc photovoltaic geographical information system (pvgis) - european commission.
- [2] Pvoutput.
- [3] Mohamed Abuella and Badrul Chowdhury. Solar power forecasting using artificial neural networks. *2015 North American Power Symposium, NAPS 2015*, 11 2015.
- [4] Acciona. ¿conoces el impacto ambiental de las energías no renovables?, 2022.
- [5] Sandra Acosta. La potencia de la energía fotovoltaica crece en españa un 28,8 % en 2021, 3 2022.
- [6] Astrum. ¿cómo funcionan los paneles solares?, 2022.
- [7] Jose Manuel Barrera, Alejandro Reina, Alejandro Maté, and Juan Carlos Trujillo. Solar energy prediction model based on artificial neural networks and open data. *MDPI*, 2020.
- [8] Bimal K. Bose. Artificial intelligence techniques in smart grid and renewable energy systems - some example applications. *Proceedings of the IEEE*, 2017.
- [9] D K Chaturvedi. Solar power forecasting: A review, 2016.
- [10] Marco Cococcioni and Eleonora D ' Andrea. 24-hour-ahead forecasting of energy production in solar pv systems. 2011.
- [11] Ricardo David, Buitrón Proaño, Gisela Valentina, and Burbano Gube. Escuela politécnica nacional facultad de ingeniería eléctrica y electrónica elaboración de una normativa para el diseño y diagnóstico de sistemas fotovoltaicos residenciales autónomos para el ecuador proyecto previo a la obtención del título de ingeniero en electrónica y control, 2010.
- [12] Red Eléctrica. Redata - componentes precio energía cierre desglose — red eléctrica.
- [13] Rosa Fernández. Electricidad: precio medio final españa 2010-2022 — statista, 2022.
- [14] M. M. Fouad, Lamia A. Shihata, and El Sayed I. Morgan. An integrated review of factors influencing the performance of photovoltaic panels. *Renewable and Sustainable Energy Reviews*, 80:1499–1511, 2017.
- [15] Raúl García. La fotovoltaica como clave para la recuperación económica, 2021.
- [16] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and Tensorflow Concepts, Tools, and Techniques to Build Intelligent Systems*. 6 2019.
- [17] Muhammed A. Hassan, Nadjem Bailek, Kada Bouchouicha, and Samuel Chukwujindu Nwokolo. Ultra-short-term exogenous forecasting of photovoltaic power production using genetically optimized non-linear auto-regressive recurrent neural networks. *Renewable Energy*, 171:191–209, 6 2021.
- [18] Boming Huang, Yuxiang Huan, Li Da Xu, Lirong Zheng, and Zhuo Zou. Automated trading systems statistical and machine learning methods and hardware implementation: a survey. *Enterprise Information Systems*, 13:132–144, 1 2019.

- [19] Iberdrola. Qué es la energía solar fotovoltaica.
- [20] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. 2014.
- [21] Castilla León. Agotamiento de reservas, energía y minería, junta de castilla y león, 2020.
- [22] Warren S McCulloch and Walter Pitts. A logical calculus of the ideas immanent in nervous activity, 1943.
- [23] M. Nia, M. Chegaar, M. F. Benatallah, and M. Aillerie. Contribution to the quantification of solar radiation in algeria. *Energy Procedia*, 36:730–737, 2013.
- [24] Rajalingappaa Shanmugamani. *Deep Learning for Computer Vision*. PacktJ, 1 2018.
- [25] E. Skoplaki, A. G. Boudouvis, and J. A. Palyvos. A simple correlation for the operating temperature of photovoltaic modules of arbitrary mounting. *Solar Energy Materials and Solar Cells*, 92:1393–1402, 11 2008.
- [26] Lida Xu, Wenan Tan, Hongyuan Zhen, and Weiming Shen. An approach to enterprise process dynamic modeling supporting enterprise process evolution. 2008.
- [27] Caiming Zhang and Weina Fu. Optimal model for patrols of uavs in power grid under time constraints.
- [28] Caiming Zhang and Yang Lu. Study on artificial intelligence: The state of the art and future prospects. *Journal of Industrial Information Integration*, 23, 9 2021.
- [29] Olympia Zogou. Experimental and computational investigation of the thermal and electrical performance of a new building integrated photovoltaic concept. 7 2011.

## Índice de figuras

1.1. Evolución energía solar fotovoltaica en España [15]. . . . .	13
1.2. Precio total del MWh en España por meses [13]. . . . .	14
3.1. Esquema simplificado del efecto fotoeléctrico en un panel fotovoltaico [6]. . . . .	18
3.2. Esquema de los componentes de la radiación. [11] . . . . .	20
3.3. Descenso de la eficiencia con la temperatura [14]. . . . .	21
3.4. Diagrama de un perceptrón [24]. . . . .	27
3.5. Gráfica de la sigmoide [24]. . . . .	28
3.6. Gráfica de la función tangente hiperbólica [24]. . . . .	28
3.7. Gráfica de la función ReLU [24]. . . . .	29
3.8. Diagrama Red Neuronal [24]. . . . .	30
3.9. Descripción gráfica del Dropout [24]. . . . .	30
3.10. Descripción gráfica del descenso del gradiente [24]. . . . .	31
3.11. Entrada a una red neuronal convolucional [16]. . . . .	32
3.12. Aplicación de dos filtros distintos para obtener dos características [16]. . . . .	33
3.13. Aplicación de dos filtros distintos para obtener dos características [16]. . . . .	34
3.14. Ejemplo de una capa de agrupación máxima [16]. . . . .	35
3.15. Arquitectura característica de una red neuronal convolucional [16]. . . . .	35
3.16. Ubicación de la instalación solar fotovoltaica a estudio. . . . .	37
3.17. Datos de la radiación directa descargados con frecuencia horaria . . . . .	40
3.18. Datos de la radiación directa interpolados con frecuencia cinco-minutal . . . . .	40
4.1. Evolución del MSE en los datos de entrenamiento y validación en el Modelo 5 . .	47
4.2. Evolución del MSE en los datos de entrenamiento y validación en el Modelo 8 . .	48
4.3. Evolución del MSE en los datos de entrenamiento y validación en el Modelo 31 .	48
4.4. Evolución del MSE en los datos de entrenamiento y validación en el Modelo 32 .	49
4.5. Evolución del MAE evaluado en los datos de entrenamiento y validación . . . . .	51
4.6. Evolución del MSE evaluado en los datos de entrenamiento y validación . . . . .	51
4.7. Evolución del MSE en los datos de entrenamiento y validación en el modelo con- volucional 1 . . . . .	53

4.8. Evolución del MSE en los datos de entrenamiento y validación en el mejor modelo convolucional 2D . . . . .	54
4.9. Evolución del MSE en los datos de entrenamiento y validación en el modelo convolucional 2D con producción . . . . .	55
4.10. Evolución del MAE en los datos de entrenamiento y validación en el modelo convolucional 2D con producción . . . . .	55
4.11. Representación de los errores en los modelos sin producción. . . . .	56
4.12. Representación de los errores en los modelos que incorporan la producción. . . .	57
5.1. Comparativa de los errores obtenidos sin incorporar la producción. . . . .	59
5.2. Comparativa de los errores obtenidos al incorporar la producción. . . . .	59
8.1. Diagrama de Gantt del proyecto . . . . .	63
8.2. Estructura de Descomposición del Proyecto . . . . .	63

## Índice de tablas

4.1. Errores modelos de redes neuronales en el conjunto de validación. . . . .	56
8.1. Costes Materiales . . . . .	64
8.2. Costes de Recursos Humanos . . . . .	64
8.3. Costes Totales . . . . .	65

